Machine Learning in Produktion

oder: Warum Software-Entwicklung auch hier wichtig ist

Data Science Projekte – Eine neue Idee

Have:

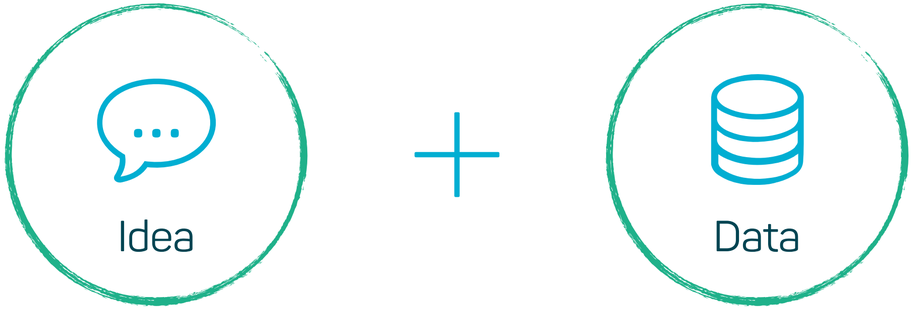

Want:

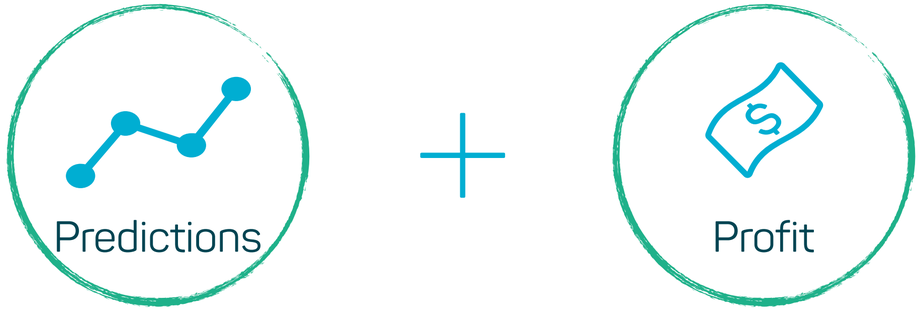

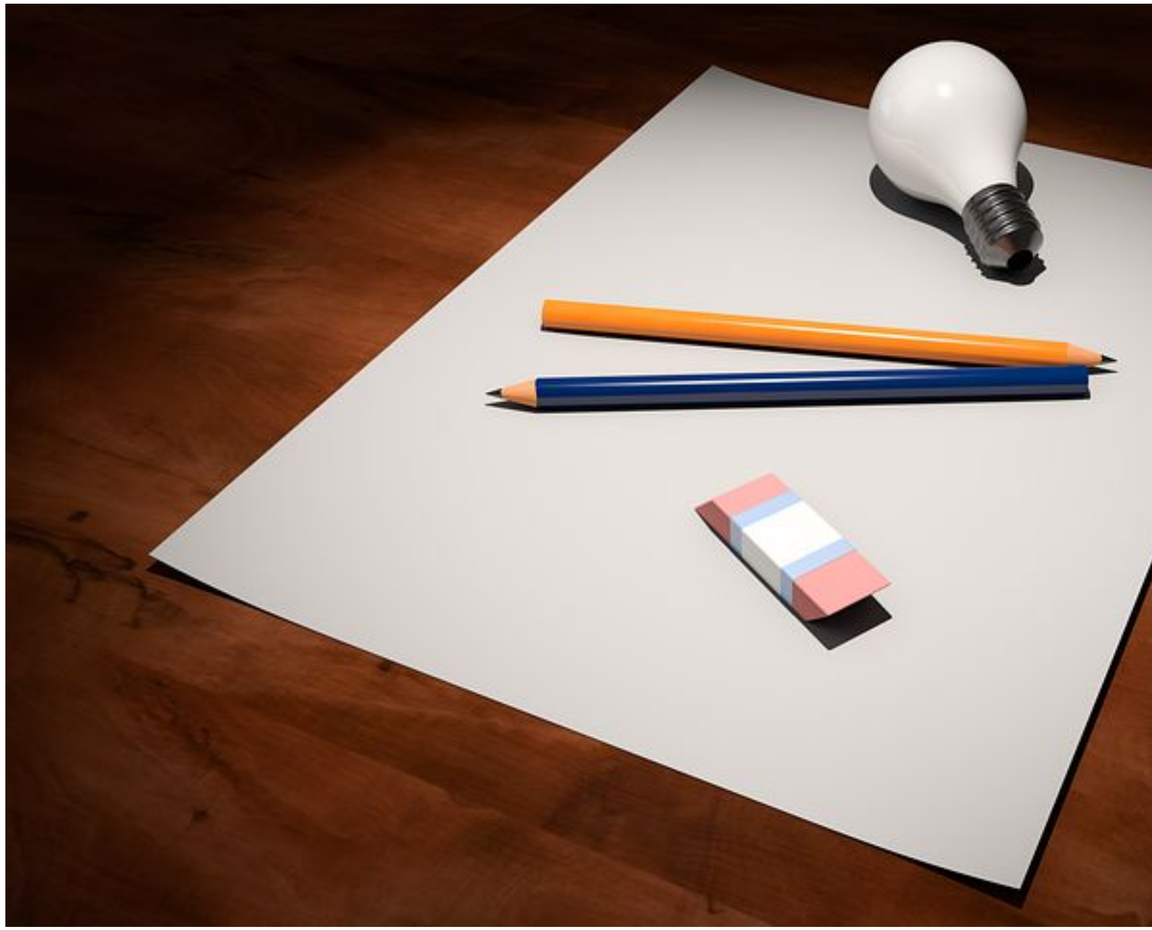

Data Projekte – Exploration

Ziel: Schnelle Exploration und schnelle Experimente

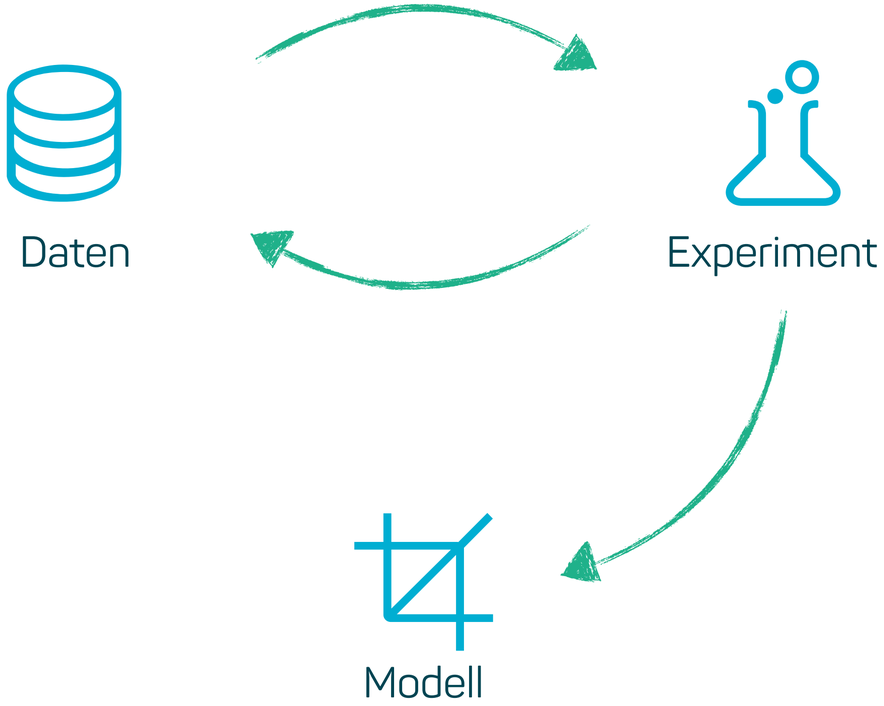

Jupyter notebook

```
data = load_data("input.csv")
data = preprocess(data)
model = train_model(data)
print(model.predictions)
```

Modell Entwicklung

- Datenbeschaffung & Speichern
- Cleaning
- Vorverarbeitung
- Modell Training
- Evaluation

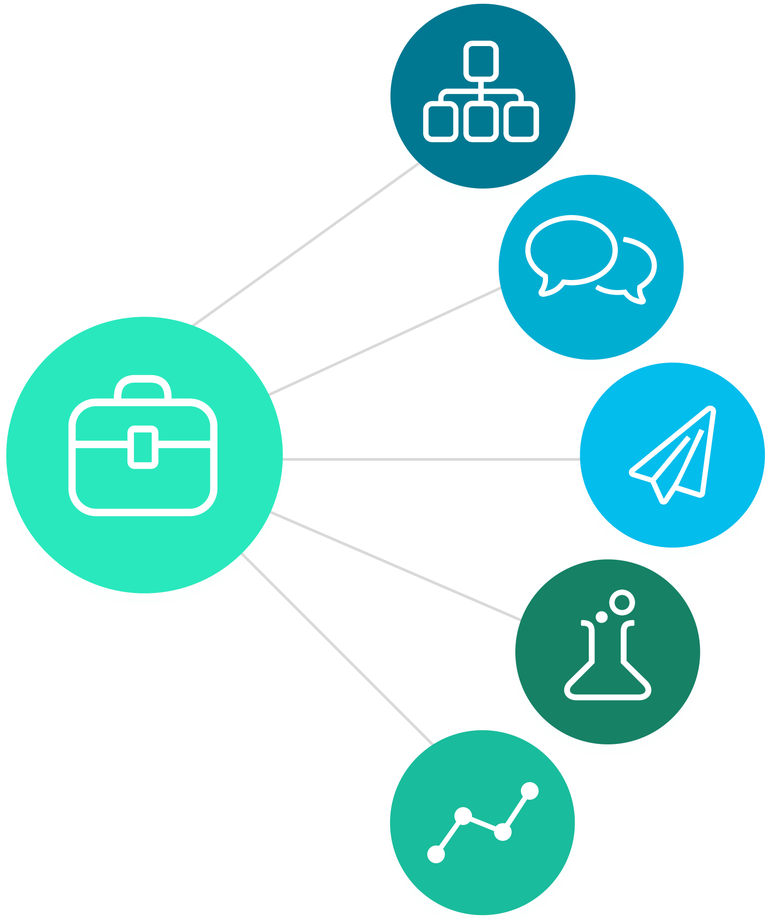

Experiment funktioniert!

Und nun?

Wie geht es weiter?

- Wie kommen die Predictions zum User?
- Wie soll das Modell deployed werden?
- Welche Bereiche des Unternehmens sind involviert?
- Woher kommen “live” Daten?
- Wie könnten User frühzeitig einbezogen werden?
- Was muss für einen wirtschaftlichen Nutzen passieren?

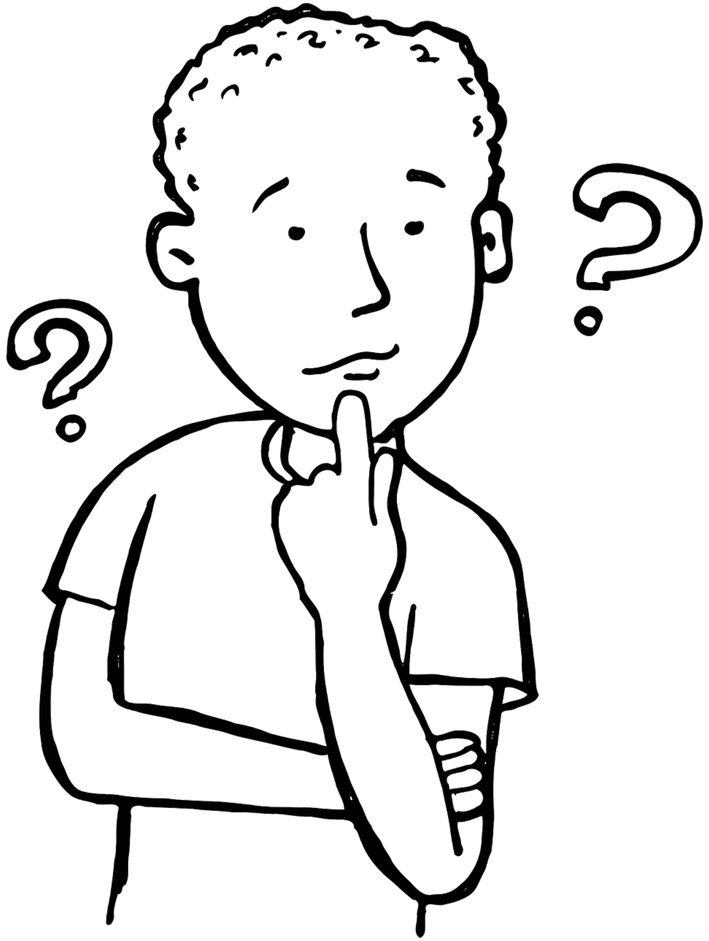

Die zwei Seiten eines Daten-Projekts

codecentric

Daten-Projekt – Zwei Perspektiven

Data Scientist

- Neue Features
- Neue Algorithmen
- Optimierung des Modells
- Visualisierung der Ergebnisse
- Verbesserung der Predictions

Jupyter notebook

```
data = load_data("input.csv")
data = preprocess(data)
model = train_model(data)
print(model.predictions)
```

Software/Data Engineer

- Schneide Module
- Artefakte und Interface
- Deployment
- Maintainable Code
- Unittests, Integrationtests
- Build Pipelines
- Automatisierung

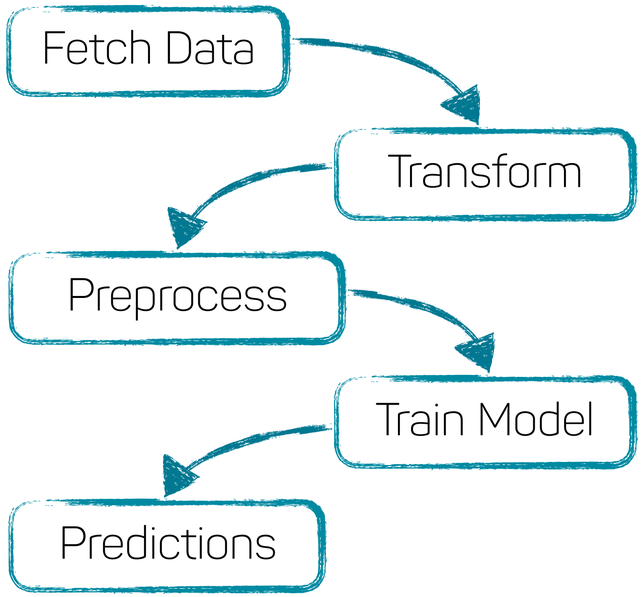

Data Science - Zyklus

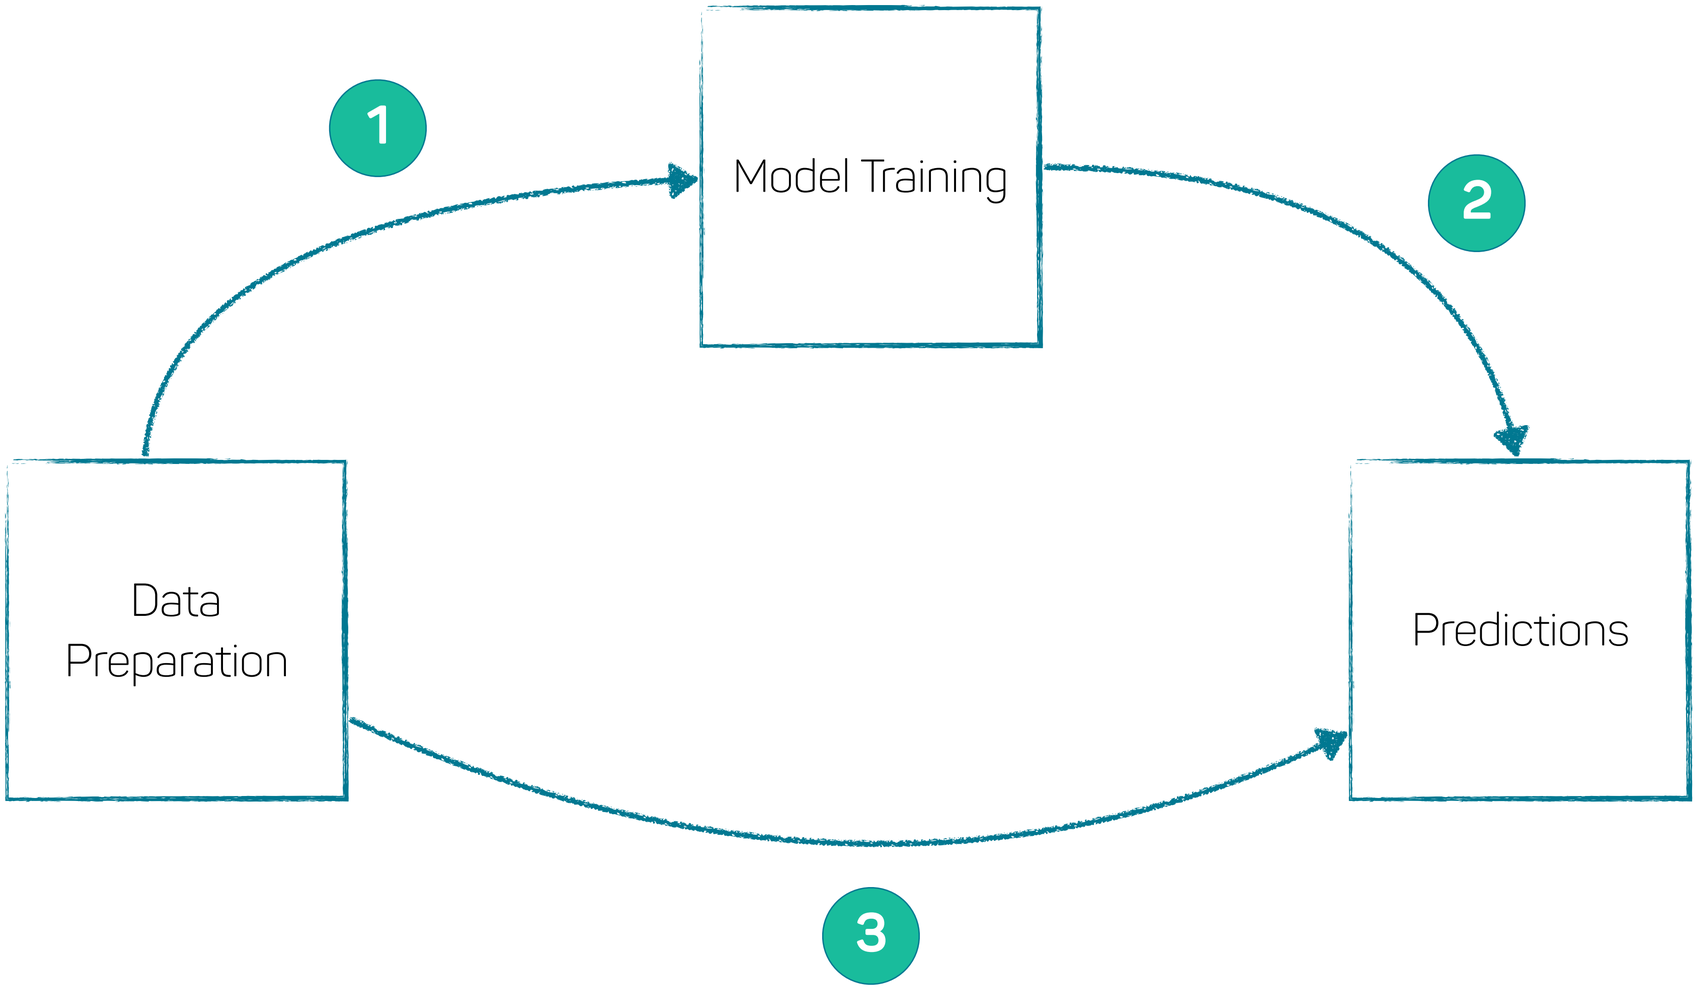

Vorbereiten der Daten

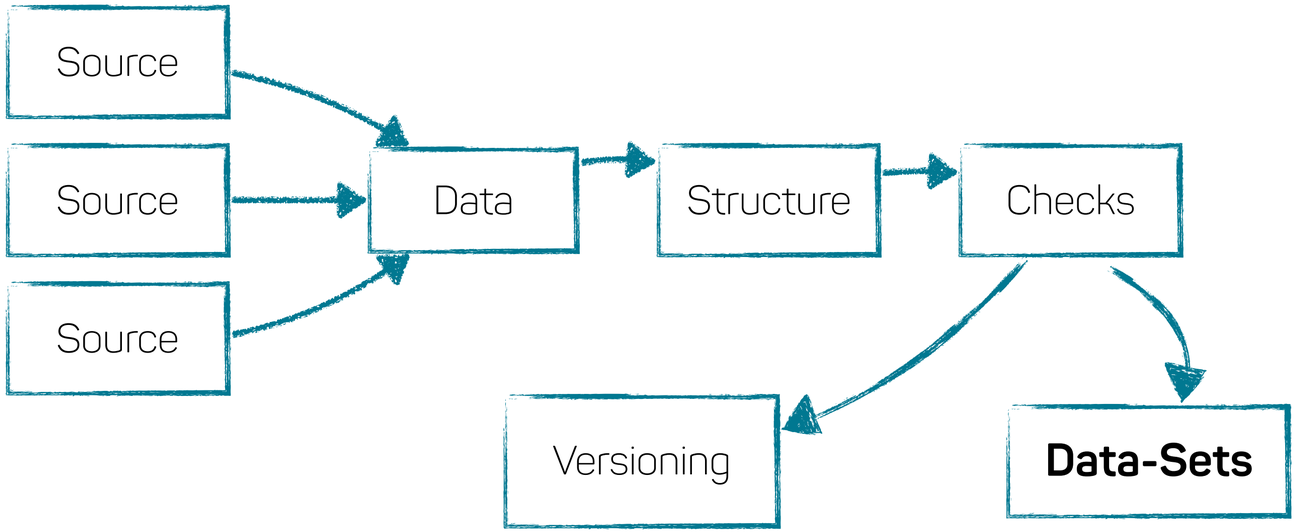

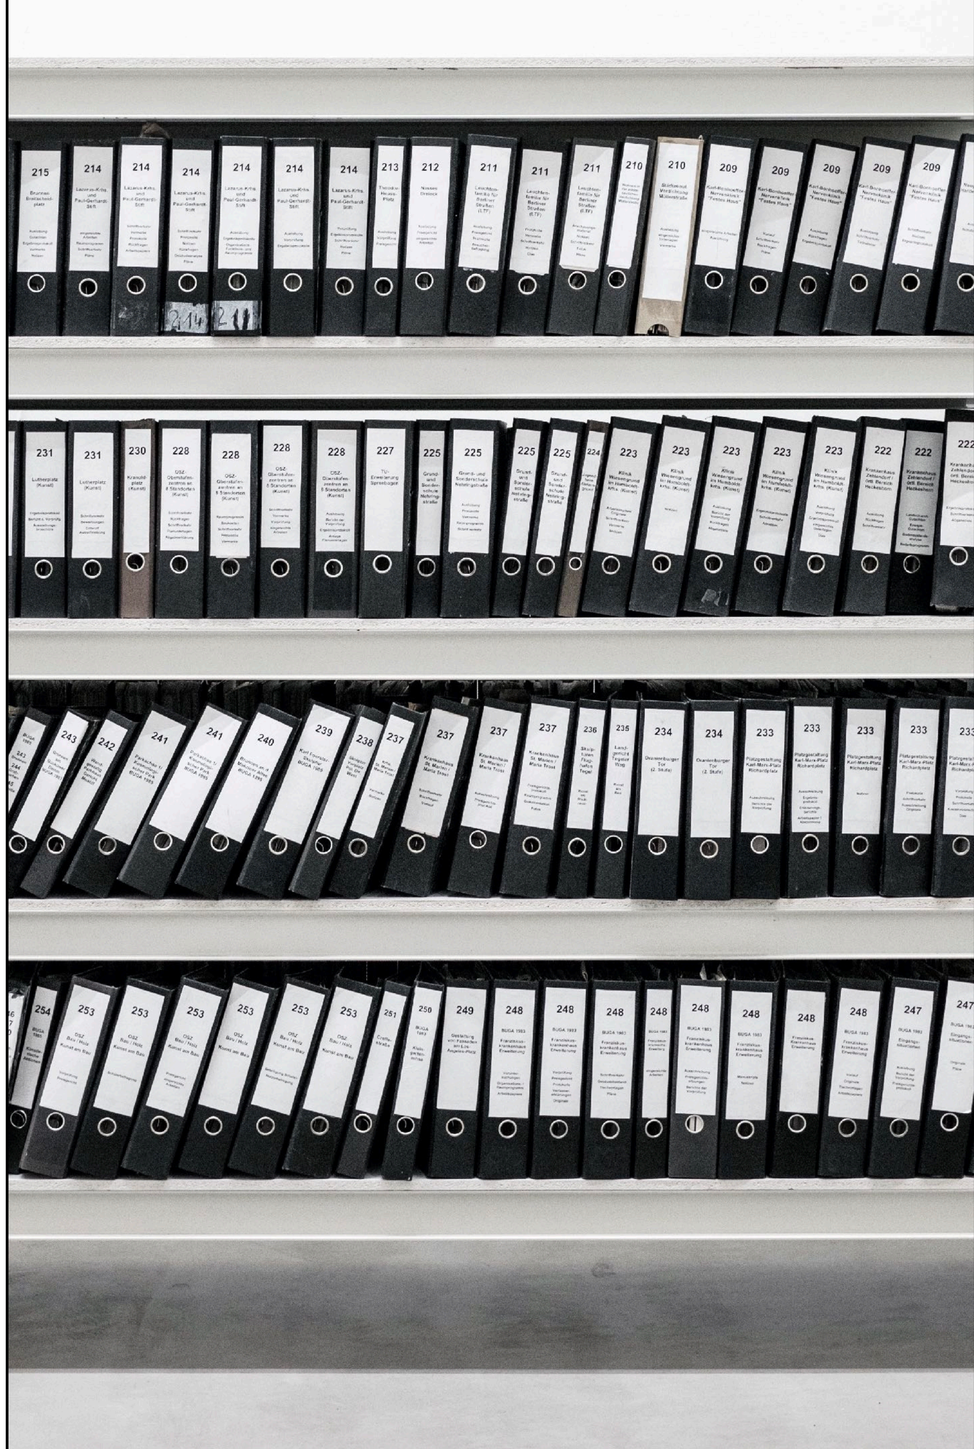

codecentric

Data Science - Zyklus

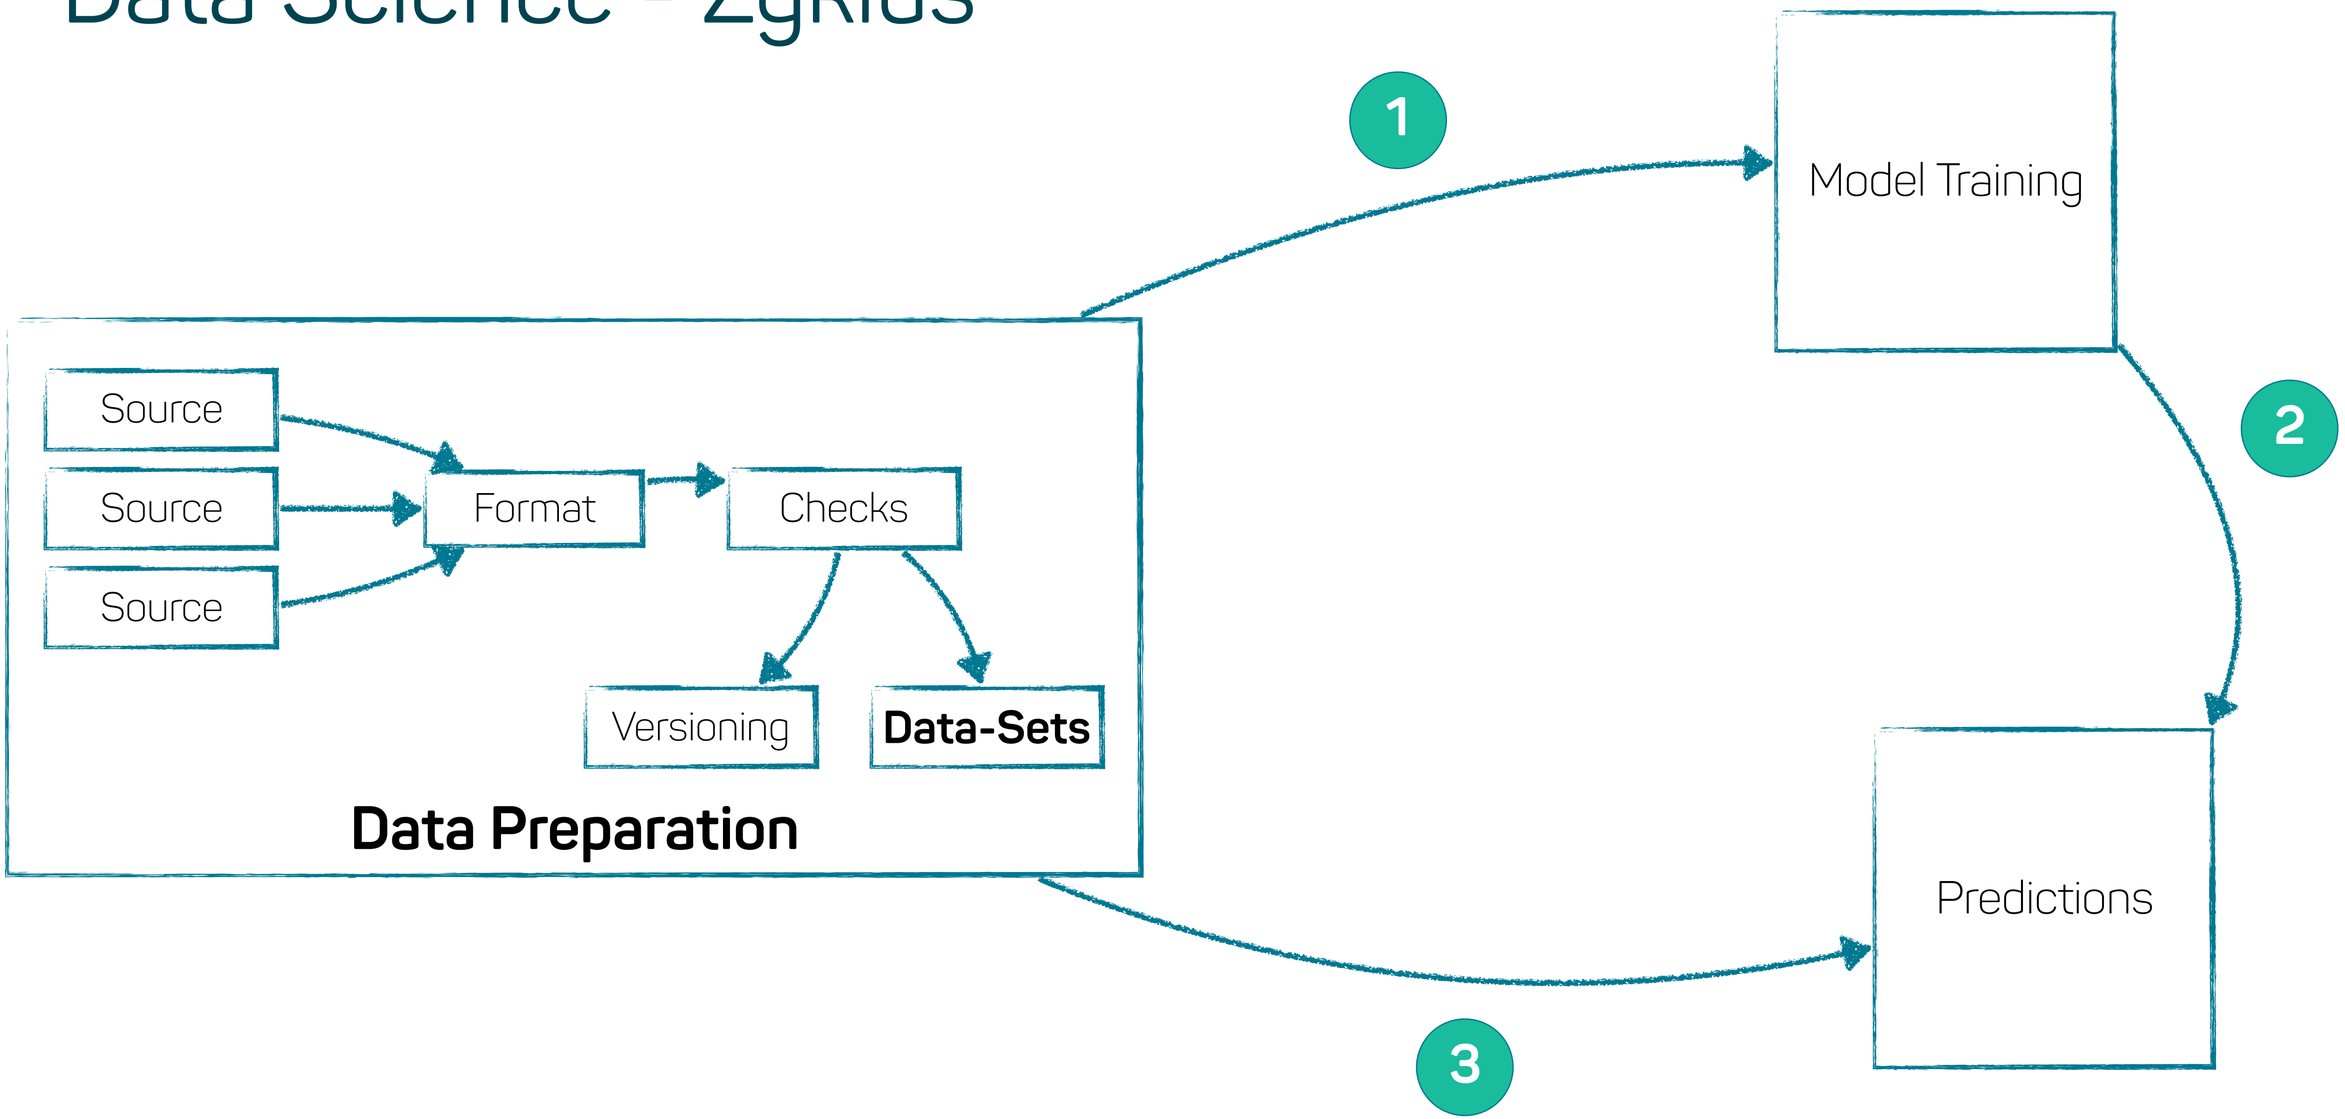

Trainieren des Modells

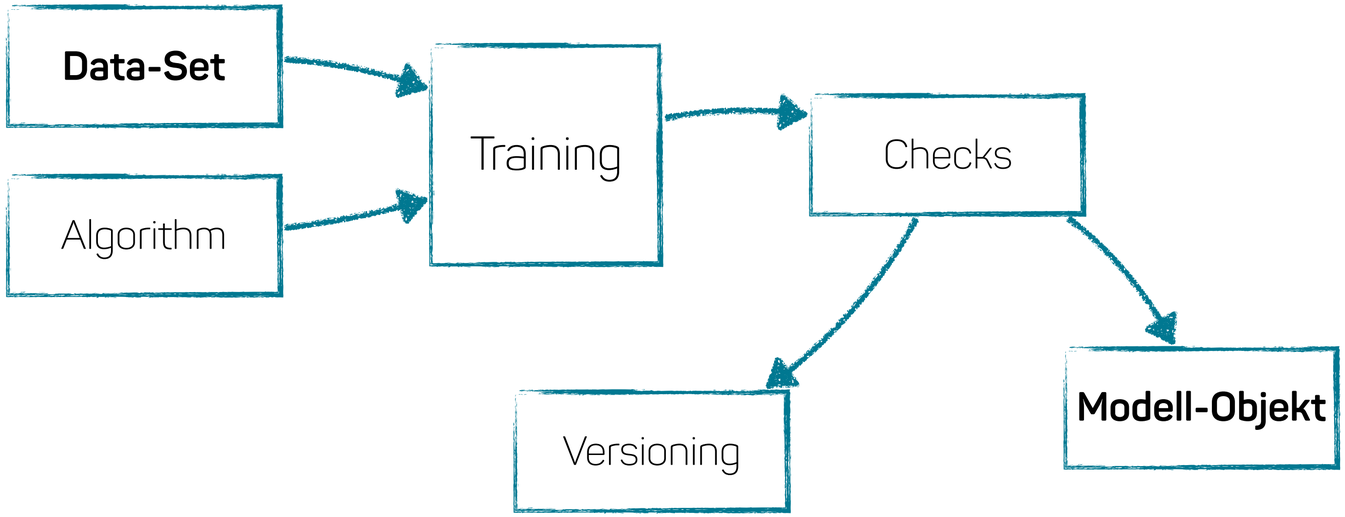

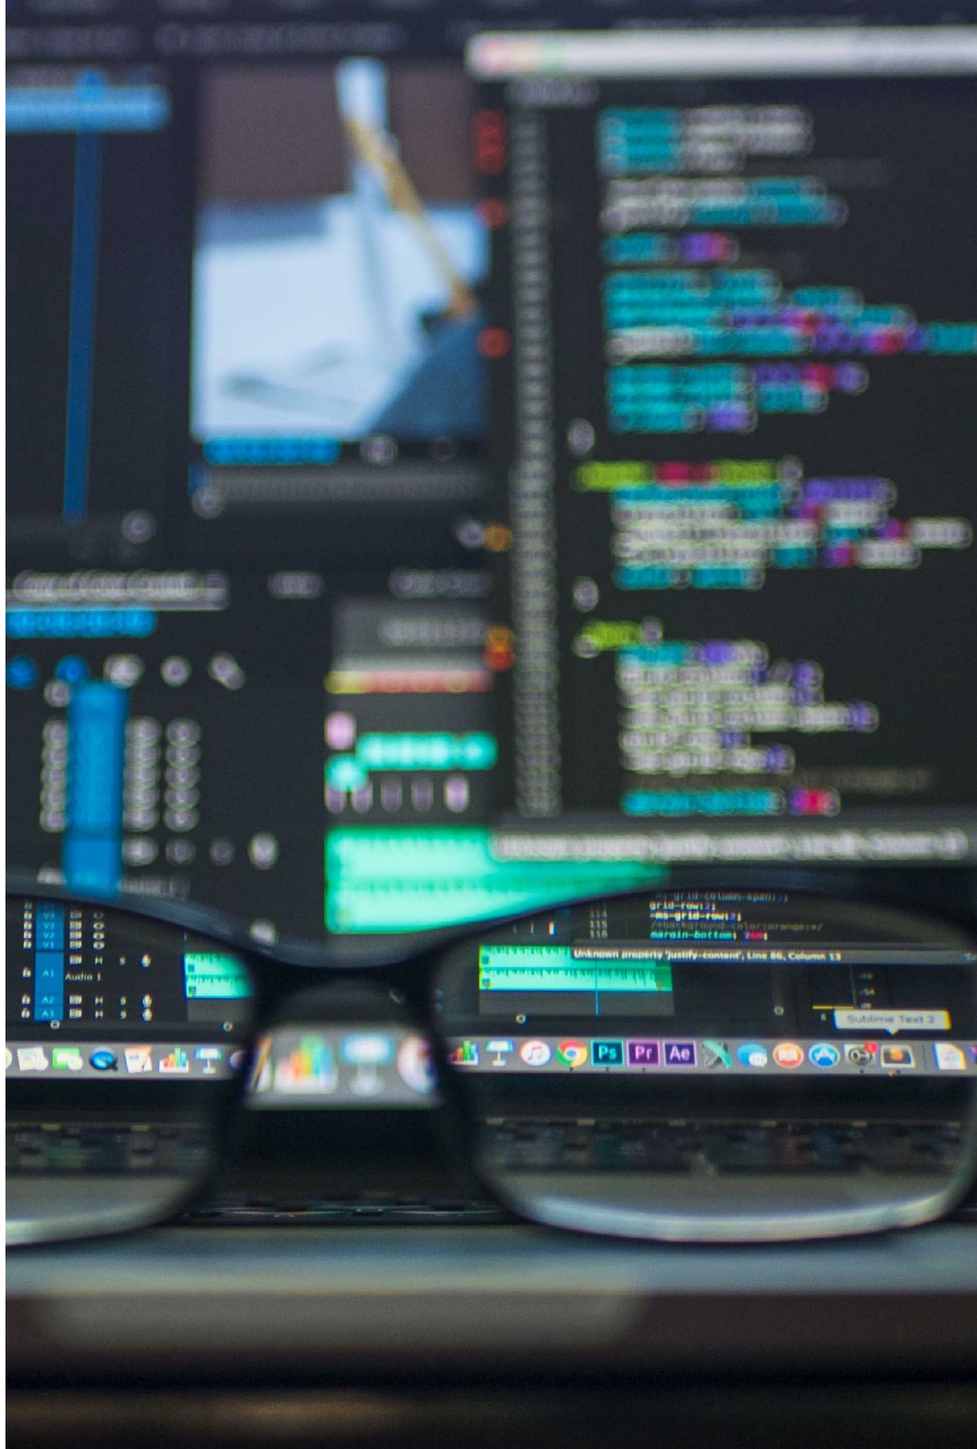

Data Science - Zyklus

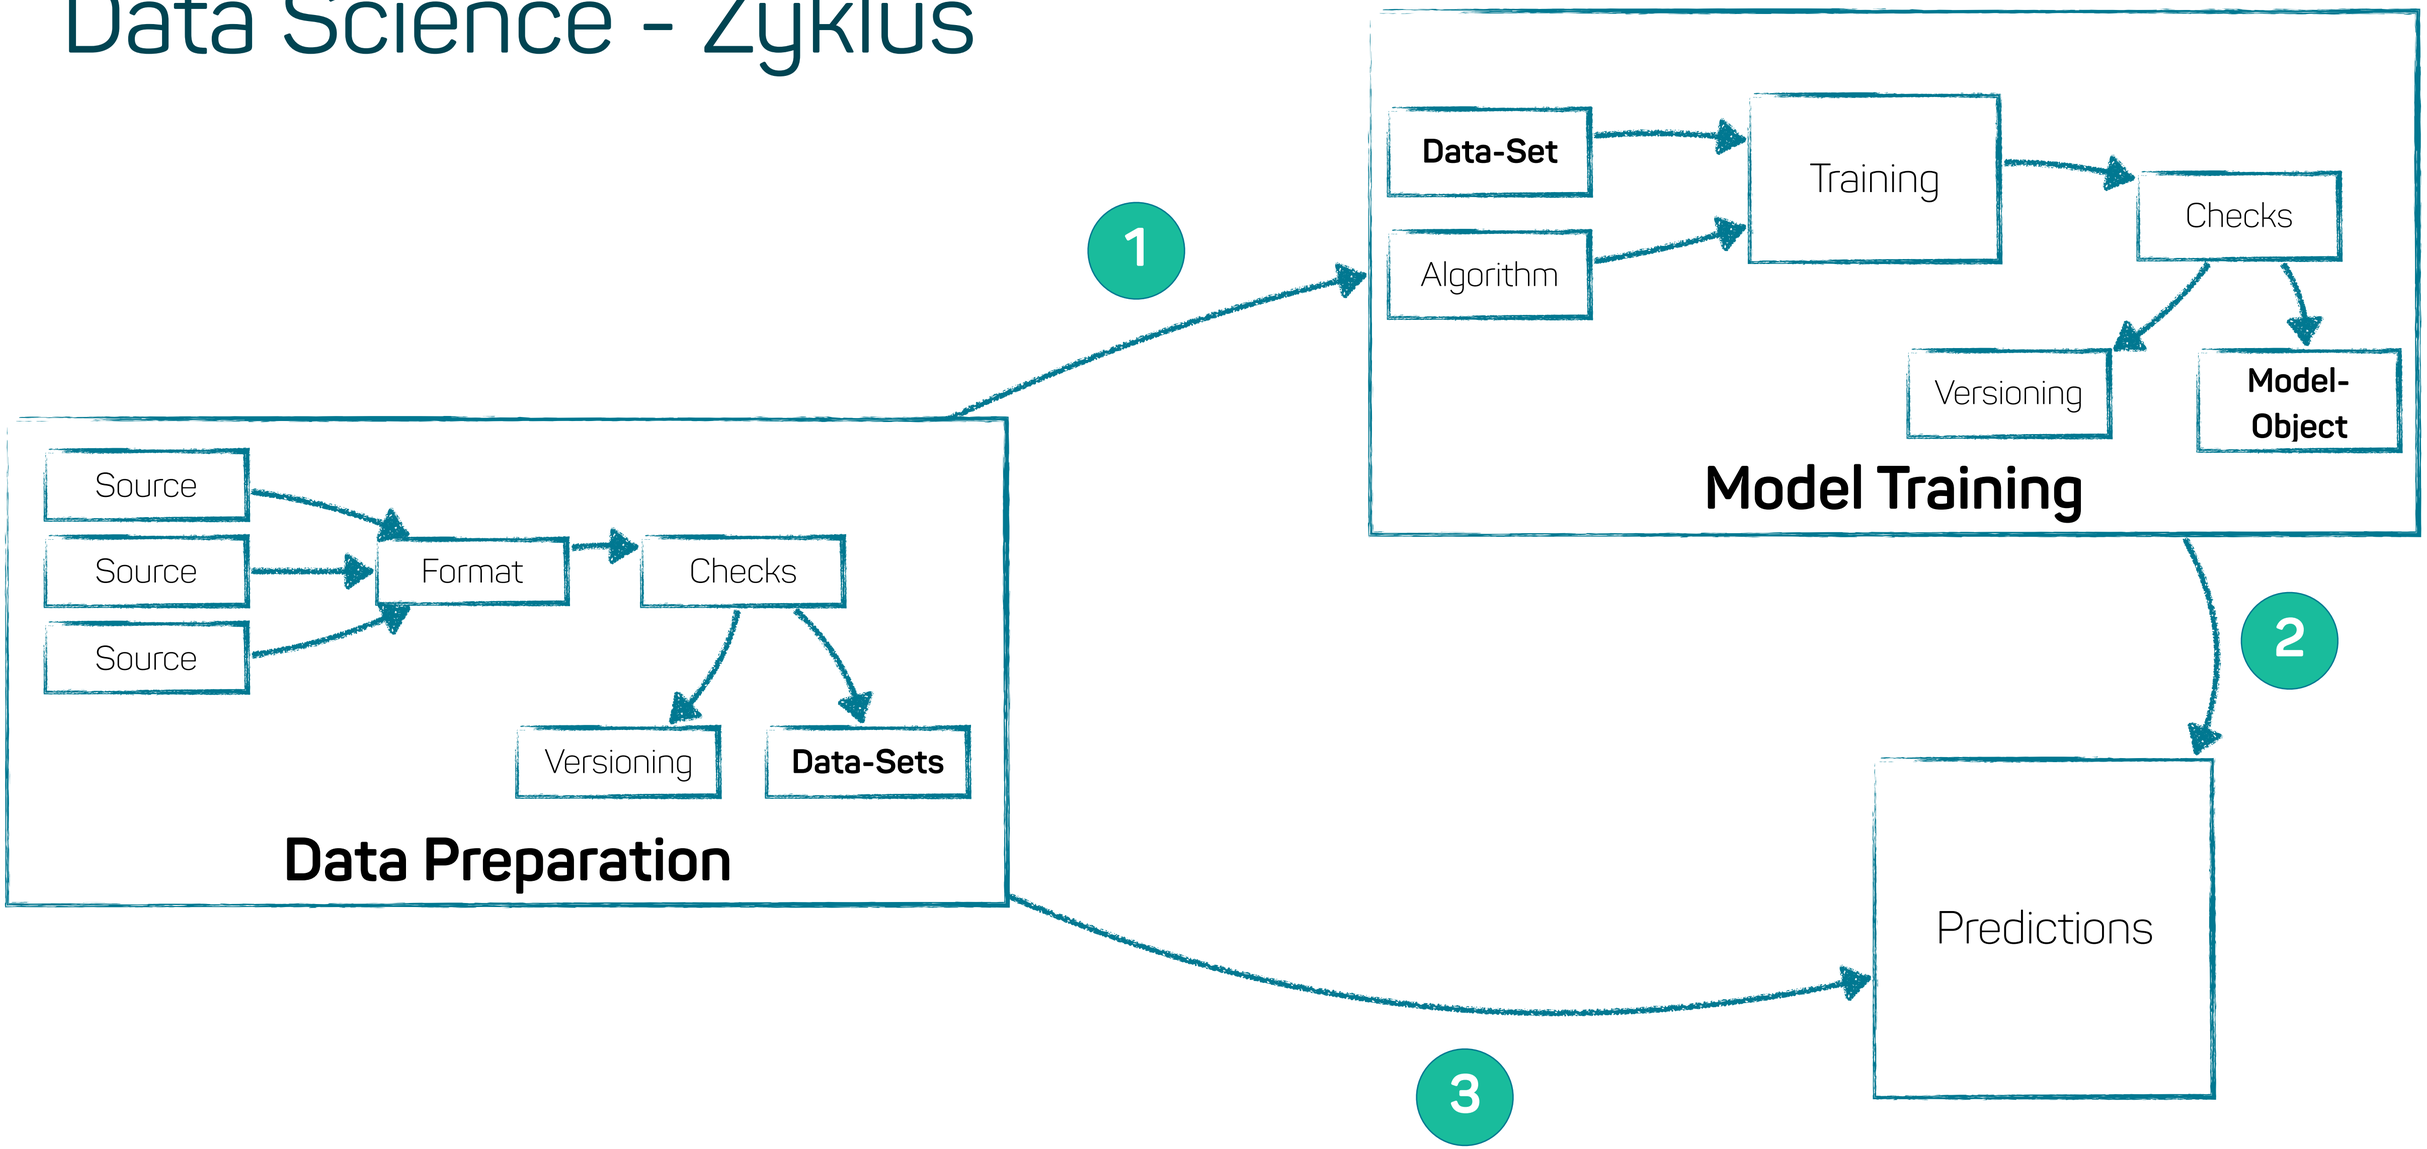

Forecasting

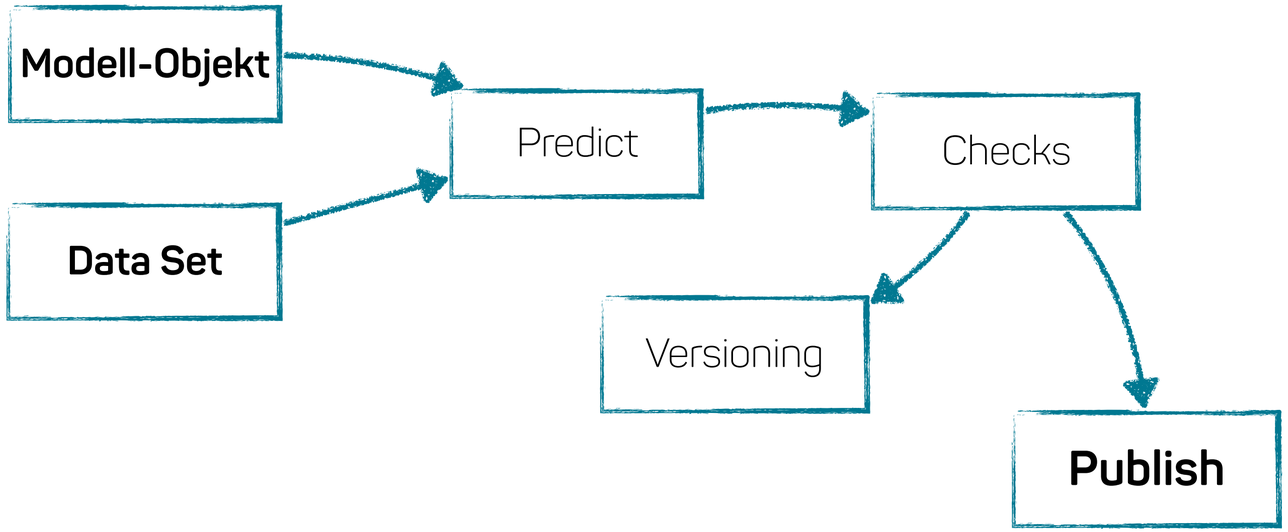

ML-Systeme

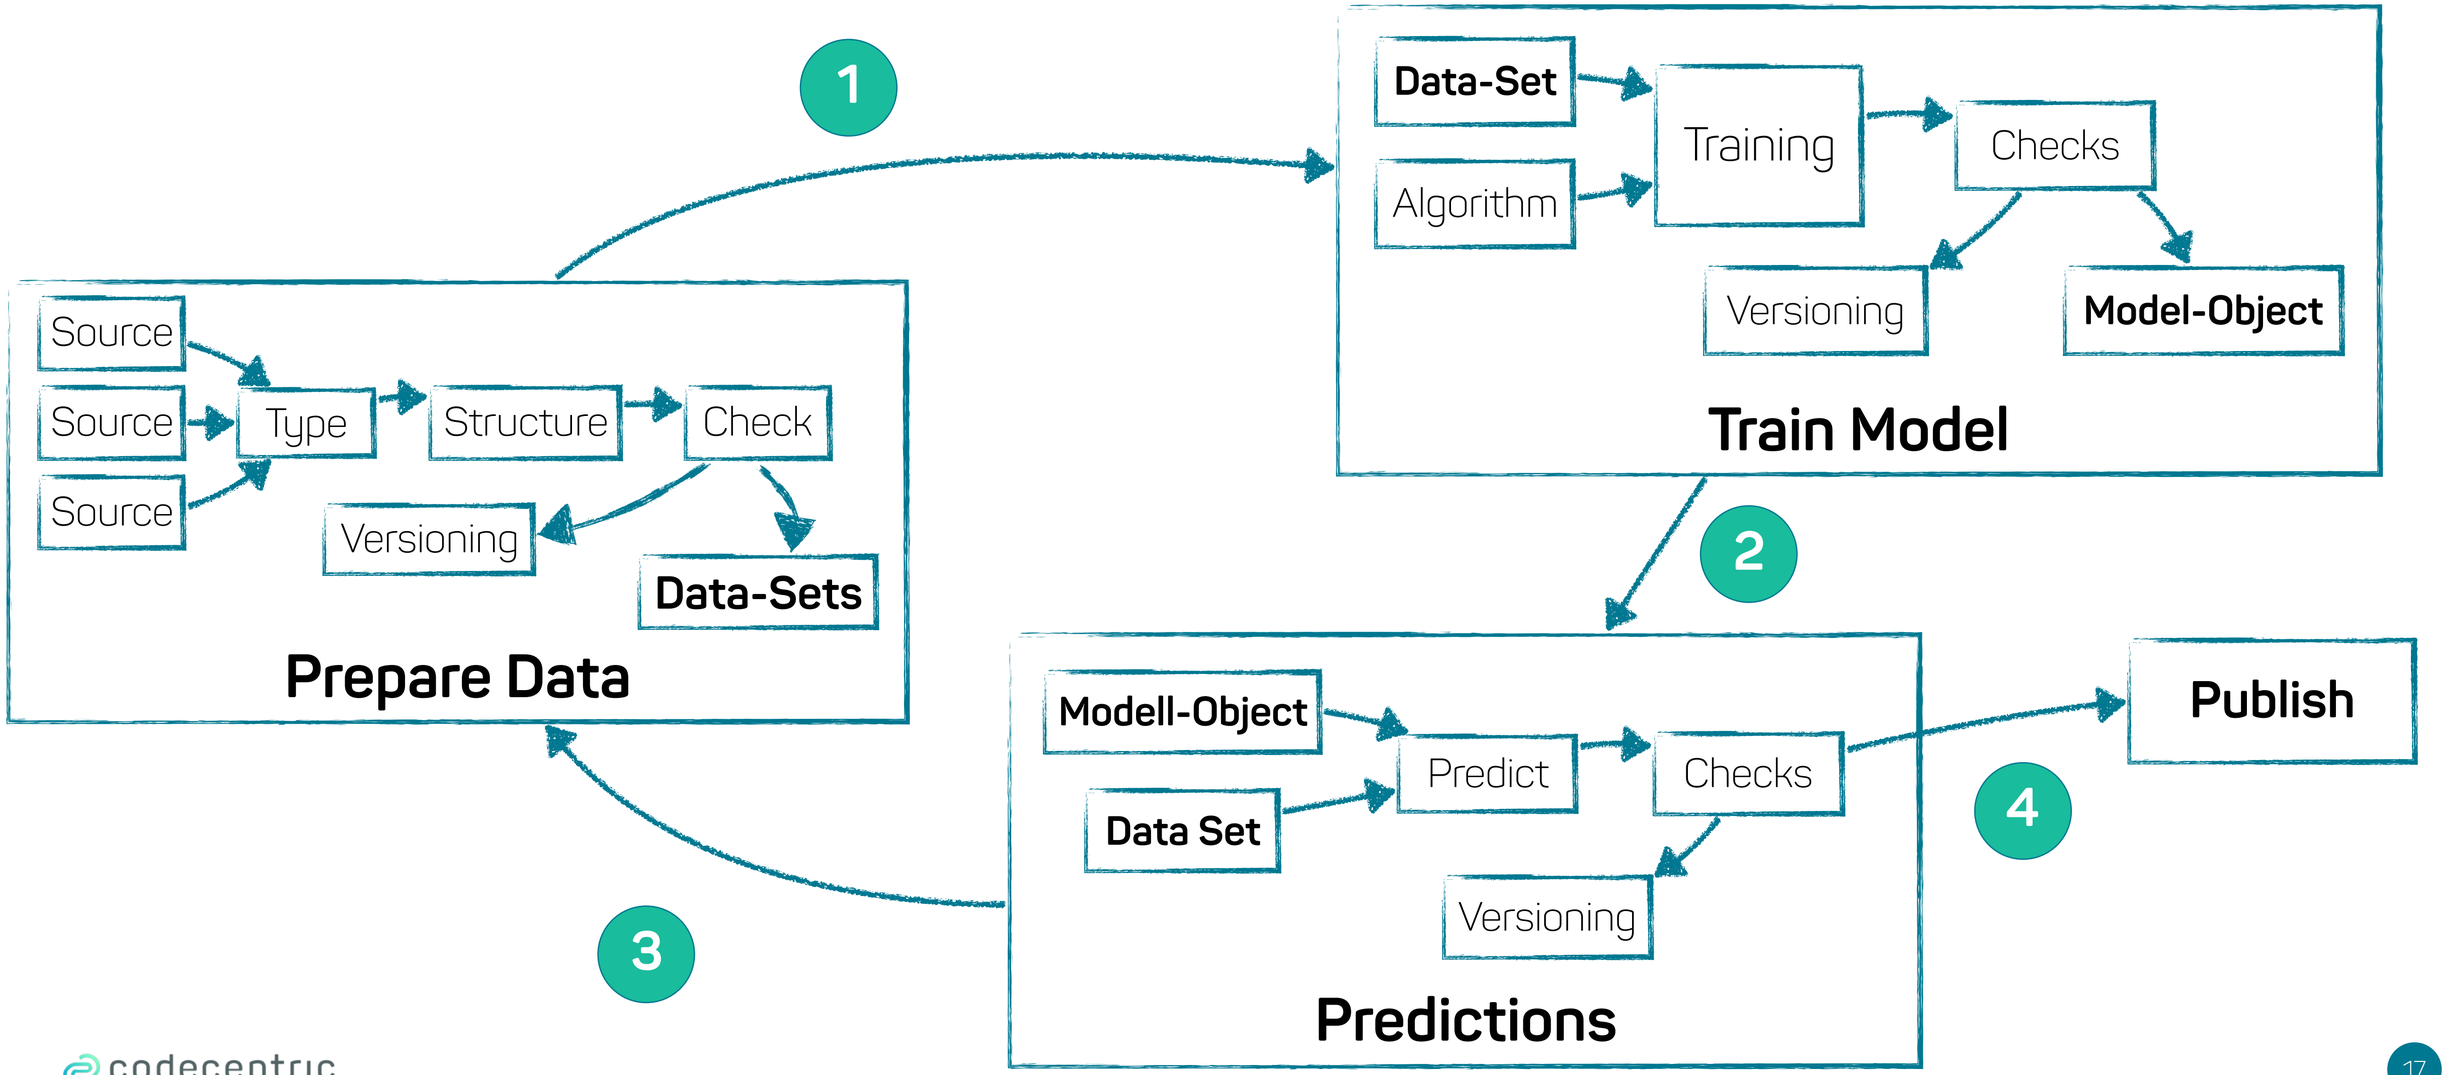
1
Source
Source
Source
Type
Structure
Check
Versioning
Data-Sets
Prepare Data
Data-Set
Algorithm
Training
Checks
Versioning
Model-Object
Train Model
2
Modell-Object
Data Set
Predict
Checks
Versioning
Predictions
3
4
Publish

ML-Systeme sind komplex

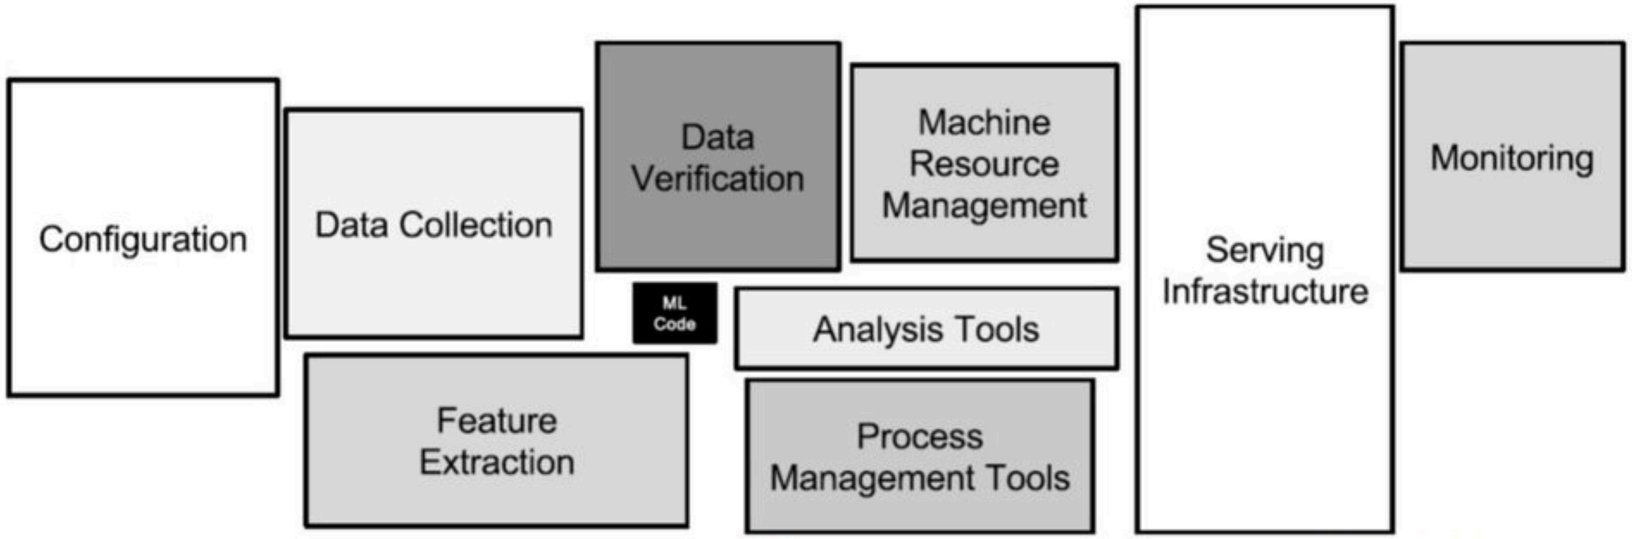

Sculley, David (Google), et al. "Hidden technical debt in machine learning systems." *Advances in neural information processing systems*. 2015.

ML-Systeme

Ziel: Automatisiertes System, um aus Daten Business Value zu generieren

- Besteht aus Data-Science und Data-Engineering Anteilen
- Beinhaltet eine Machine Learning Komponente
- Ist ein Software System mit “Intelligenz”
- Verfügen über einen Continuous Improvement Cycle
- Sind Software Systeme

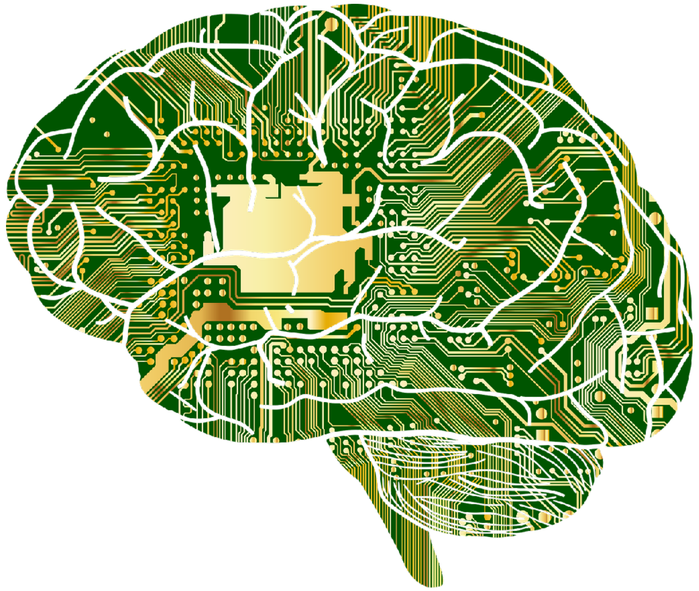

Machine Learning Deployment

codecentric

ML Deployment - Das Modell

Iterativer Prozess

Das Modell

jupyter

mxnet

TensorFlow

scikit learn

Keras

PyTorch

ONNX

PMML Predictive Model Markup Language

ONNX - Open Neural Network Exchange

Ziel: Alle Modelle in einheitlicher Laufzeitumgebung

- Open Source Standard für ML Modelle
- Bietet eine einheitliche Representation für Modelle
- Wird von großen Firmen unterstützt

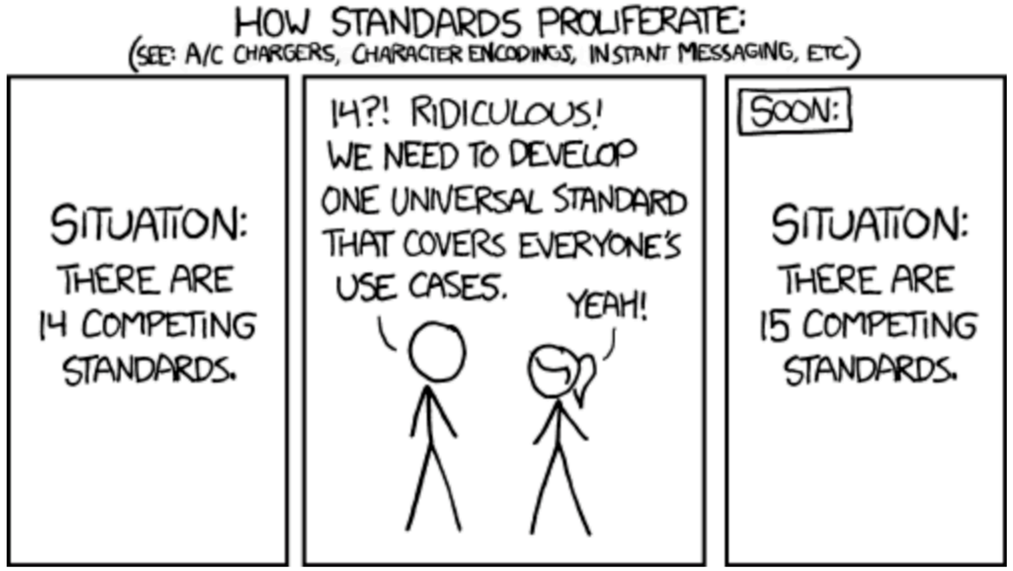

Deployment - Runtime

- Deployment von Code -> Docker
    - Deployment von Containern (K8s)
- TensorFlow Serving
- AWS SageMaker
- Google Cloud ML Engine
- Azure ML Service
- FaaS

- Inference != Training

Deployment - Batch vs Online

- Batch: Speichern & Exportieren der Resultate zur weiteren Verarbeitung
    - Langsameres Feedback
    - Einfacher zu implementieren
- Online: API, PubSub, Datenbank
    - Schnelle Reaktionszeiten
    - Häufig einhergehend: kürzere Feedbackzyklen
    - Aber auch: komplexere Evaluierung
- Außerdem zu beachten:
    - Skalierung
    - Infrastruktur / Monitoring
    - Kosten
    - Komplexität des Modells

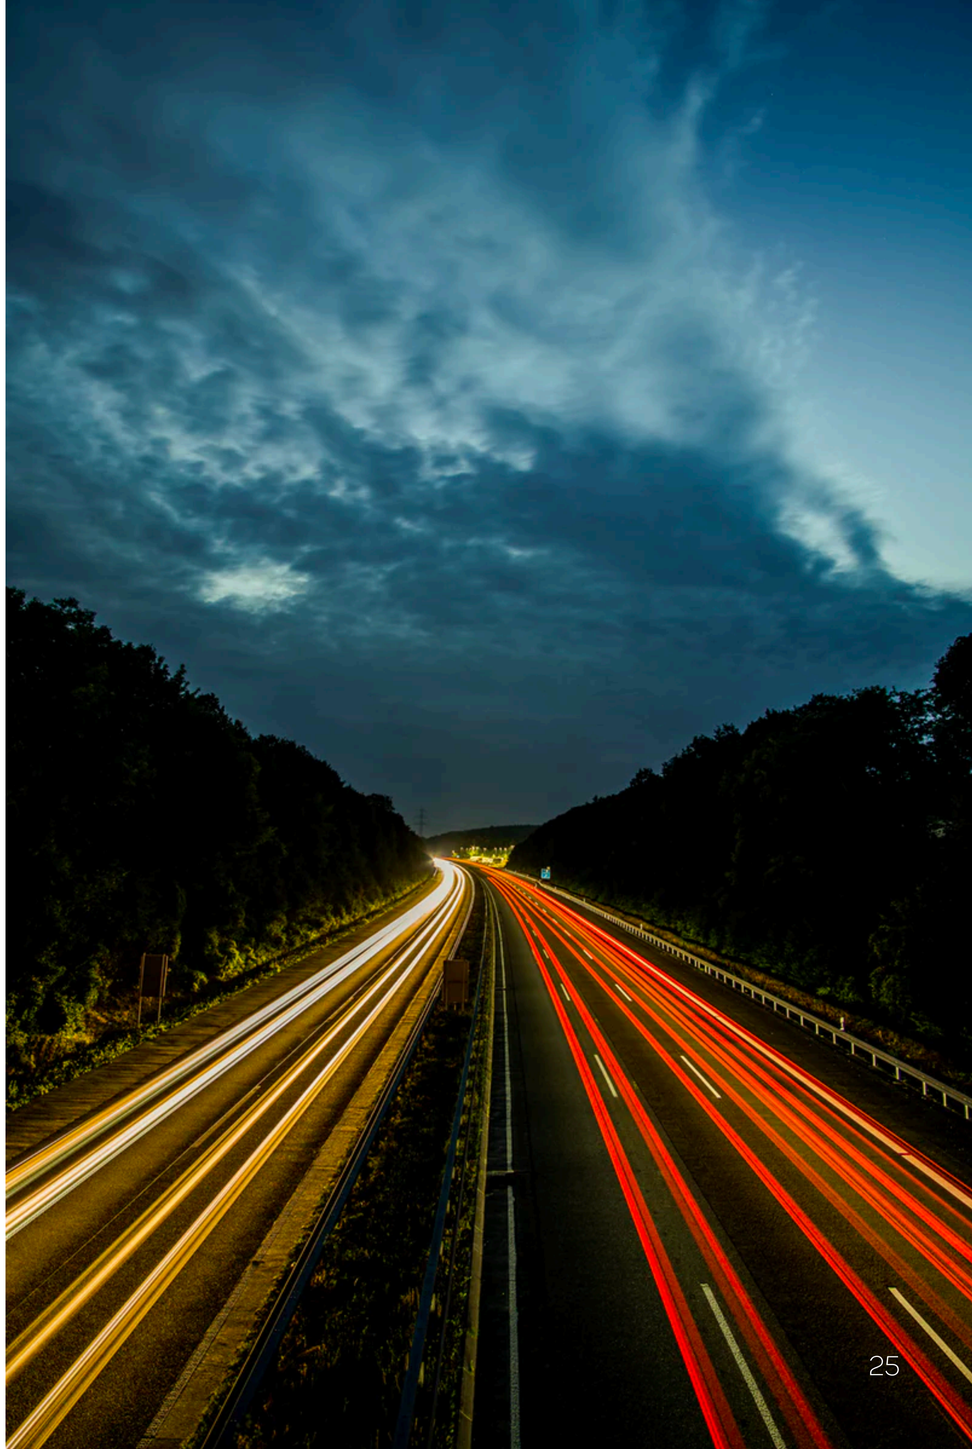

Deployment - Scheduling & Orchestrierung

- Scheduling -> Airflow/Luigi
  - Tool zum kontinuierlichen Ausführen des Cycles
  - Löst Dependencies zwischen Tasks

- Orchestrierung bei
  - Feature Engineering
  - Hyperparametertuning

Deployment - Feedback

- Einfach: Scoring Evaluierung
  - Samples mitloggen / extrahieren
  - Metriken bereitstellen

- Challenge: Business Feedback für Backfeeding bekommen
  - Feedback häufig erst lange nach der Prediction möglich
  - Feedbackkanal häufig nicht vorgesehen

Monitoring

- Technisches Monitoring:
  - Laufen Predictions durch? Wie ist die Cycle-Time?
  - Wie ist die Auslastung der Ressourcen: CPU/RAM/IO
- Fachliches Monitoring:
  - Verteilung der Klassen innerhalb der Predictions
  - Grundverteilung der Input Daten
- Nachträgliche Evaluierung:
  - A/B Testing: Aufteilung in unterschiedliche Gruppen
  - Post-Eval: Zurückschauen in die Vergangenheit auf alte Prognose und mittlerweile bekannte Ground-Truth

ML Deployment - Applikationssicht

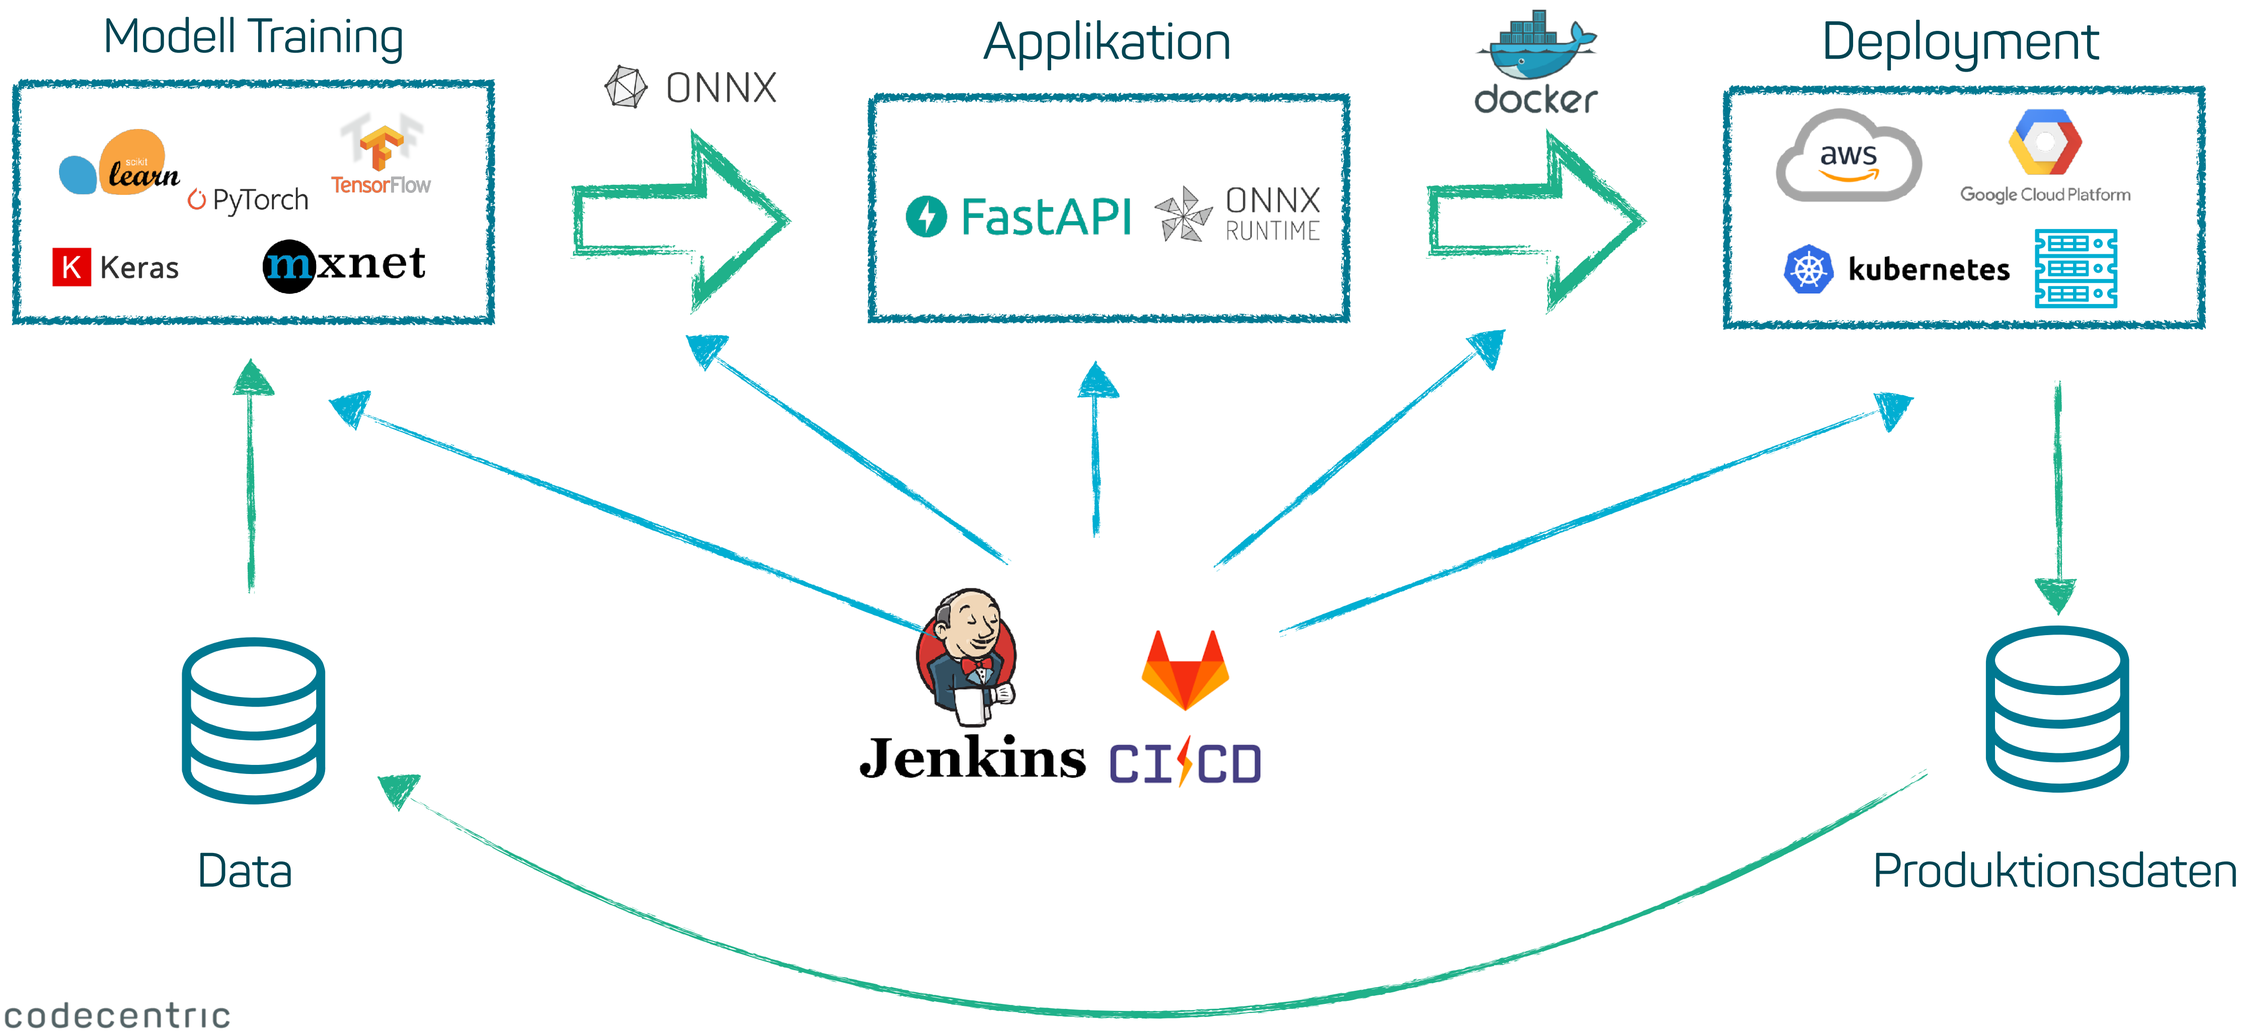

Weitere hilfreiche Tools

Data Version Control / Version Control

ML Deployments

Beispiel aus der Praxis - Ausgangslage

Churn Prediction, Recommender

Erste Modelle mittels R implementiert

Komplett manueller Prozess

Langwierig und deshalb wenig genutzt

Skalierung nicht möglich

- Technisch (lokaler Rechner, on-premises)
- Business (Ausrollen in mehrere, unabhängige Regionen)

Beispiel aus der Praxis

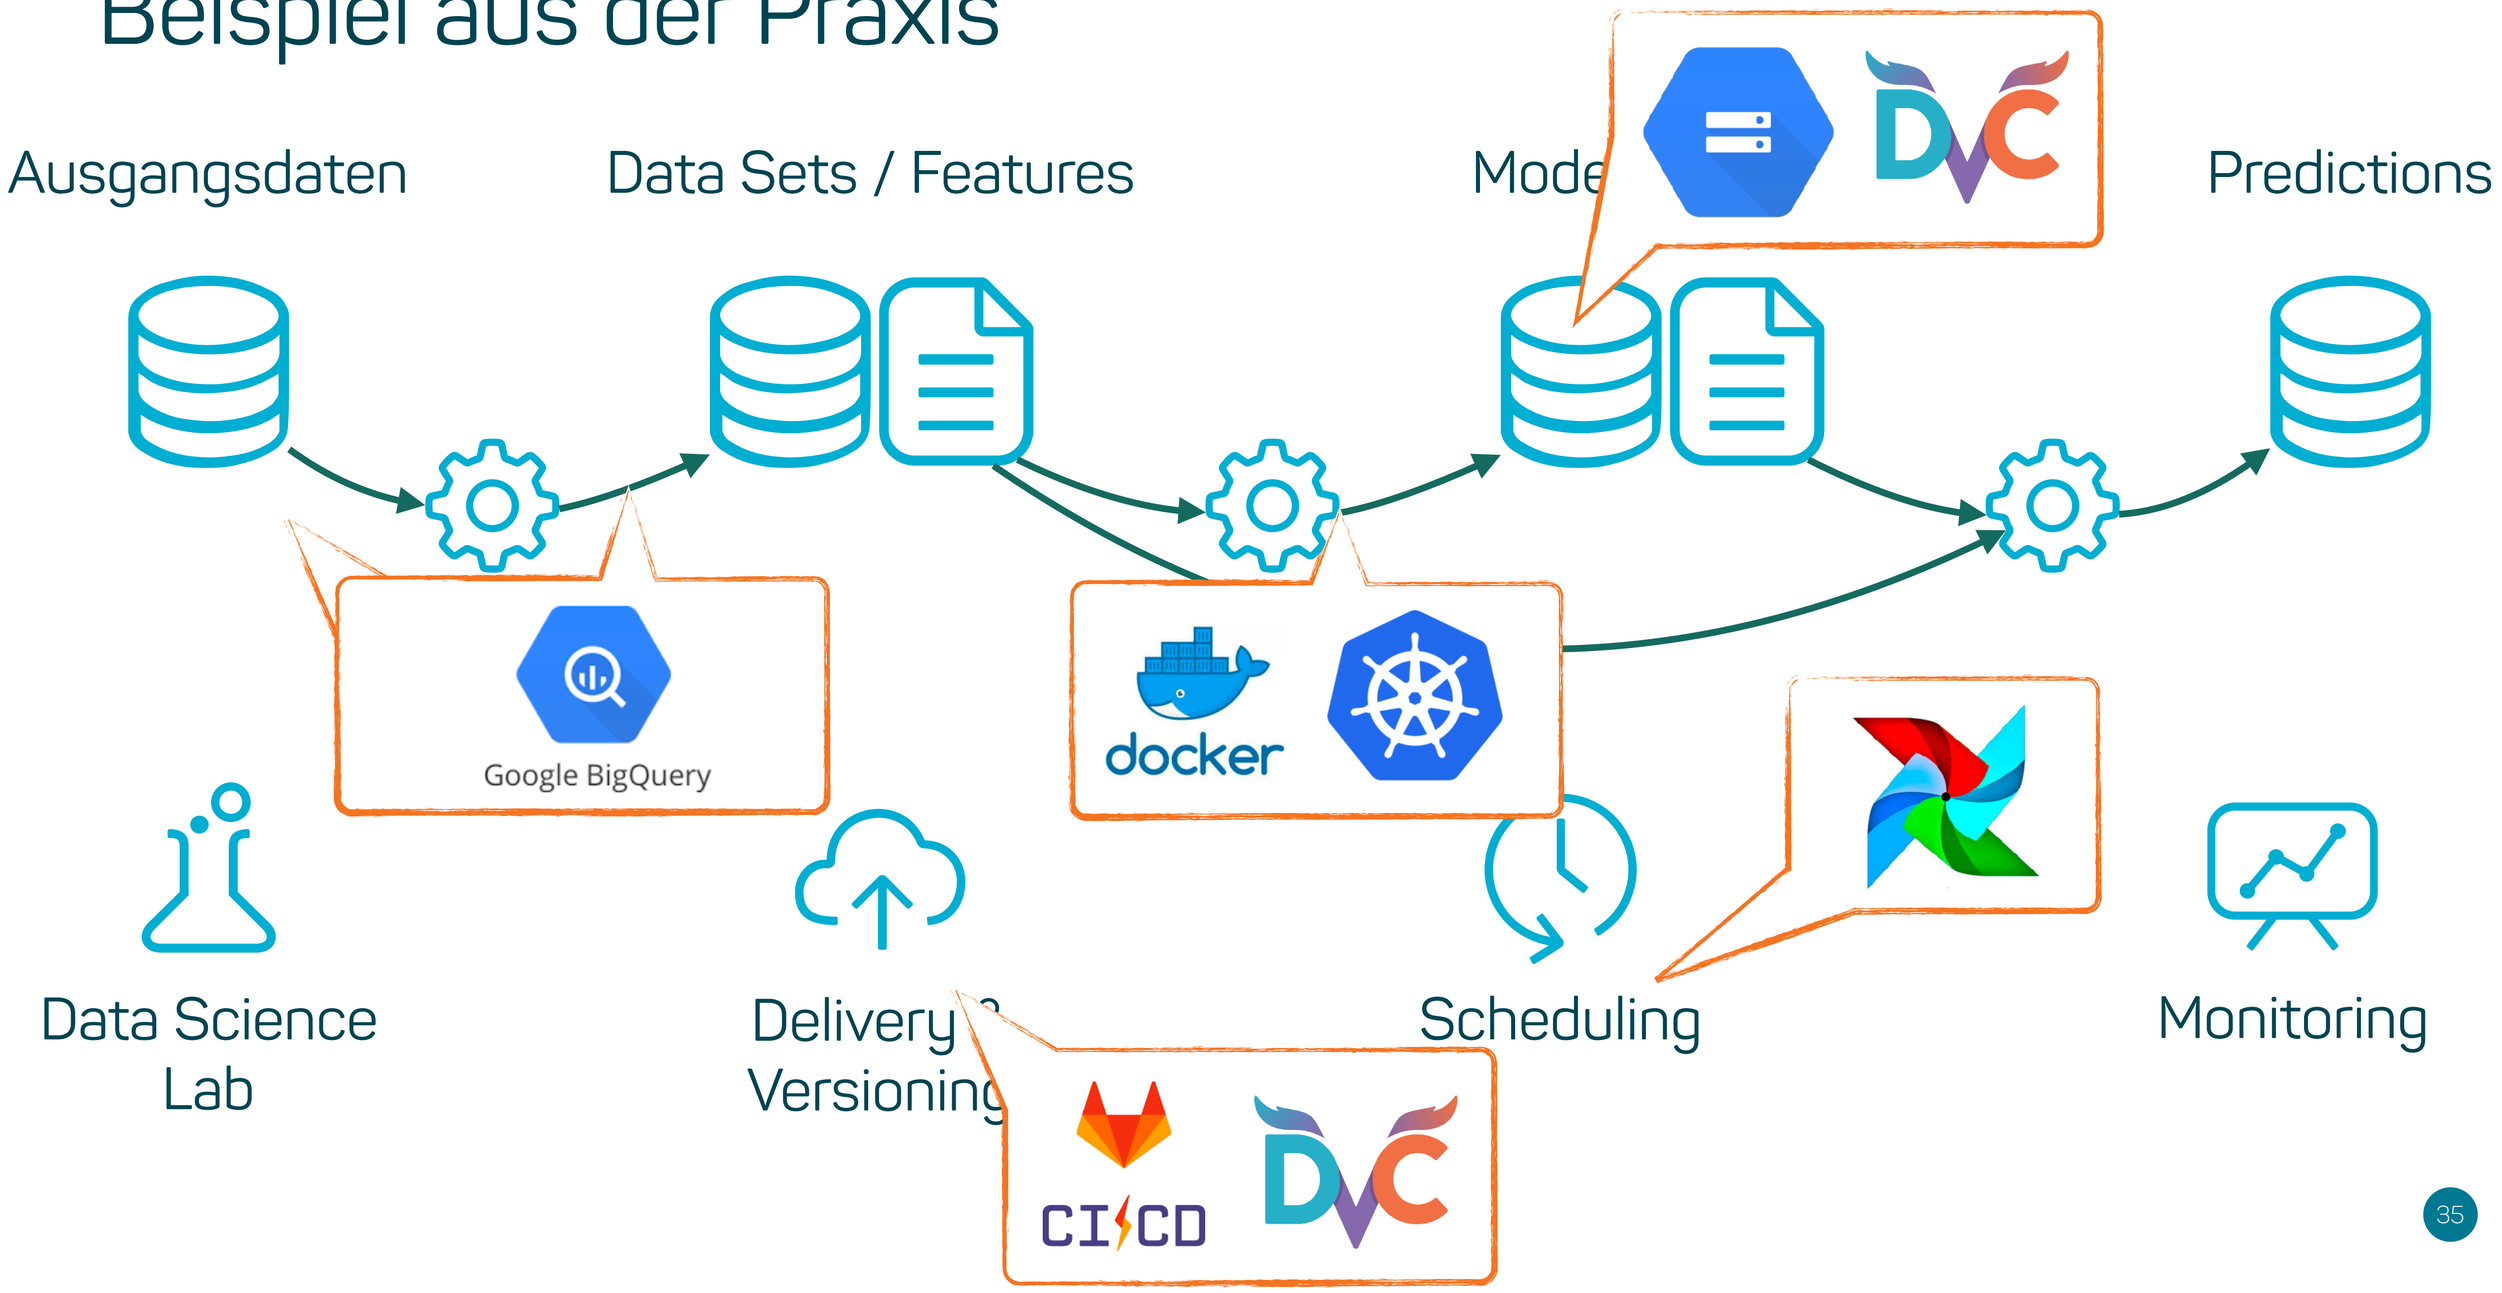

Beispiel aus der Praxis

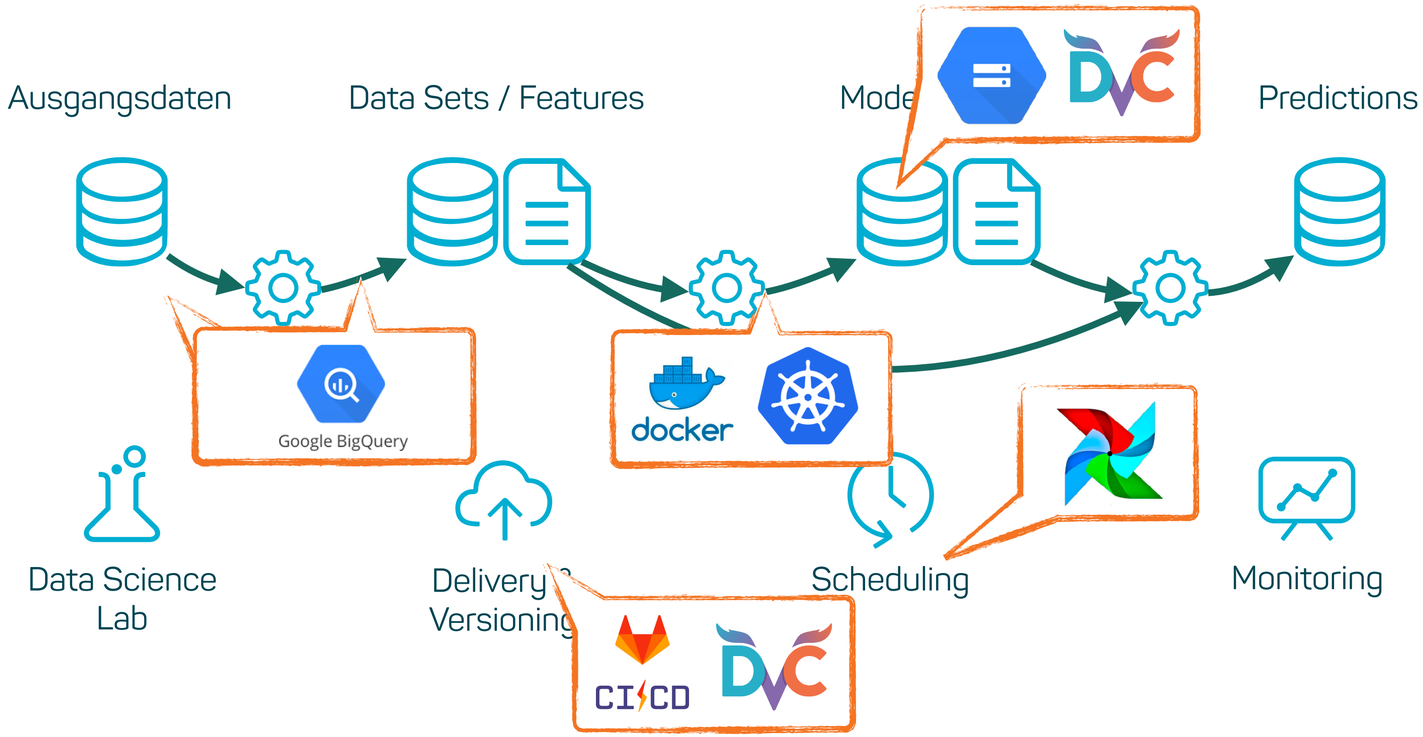

Eine mögliche technische Lösung unter Berücksichtigung von

- Vorhandener Infrastruktur
- Vorgaben bzgl. Cloud Nutzung
- Skills
- Flexibilität

- Viele spezialisierte Lösungen am Markt
- Erste All-in Lösungen on-Prem
- ML-Plattformen der großen Cloud Anbieter

Technische Herausforderungen

- Experiment Tracking
- Reproduzierbarkeit
- Skalierung & (lokale) Infrastruktur
- Monitoring
- Hohe Anzahl verschiedener Komponenten
- (noch) wenige Standards
- Integration in bestehende Umgebung
- Datenschutz erhöht die Komplexität

PoC – Mindset

Aufgabe: Evaluierung der Durchführbarkeit

- Entwickle ein einfaches Basis Modell
- Treffe pragmatische Entscheidungen und Annahmen
- Schärfe den Use-Case / Business Case
- Helfe dem Management zu Verstehen (Business Metrics)
- Nur Experimente liefern belastbare Entscheidungsgrundlagen
- Arbeite data-driven nicht discussion-driven

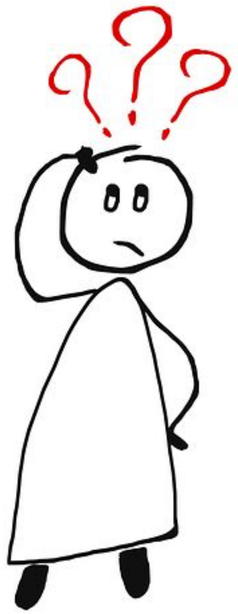

PoC – Mindset

- Jupyter Notebooks sind am Anfang okay
- Reproduzierbarkeit und Vergleichbarkeit sind wichtig
- Beginne mit Automatisierung, Bash-Scripte sind okay
- Entwickle ein "ausreichend gutes" nicht "das beste" Modell
- Denke an das Big Picture
- Sobald ein Mehrwert geschaffen ist Integration

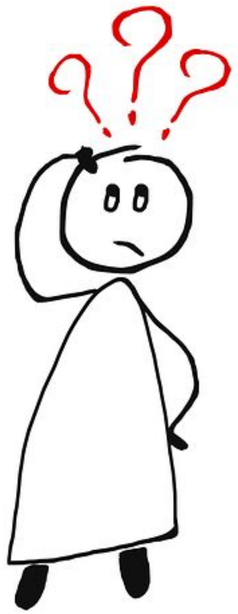

Minimal Valuable Product — Pipelines

Herausforderung: Deployment der gesamten Pipeline

Trainings-Phase

Prediction-Phase

Minimal Valuable Product

Aufgabe: Integration des Modells in die vorhandene Infrastruktur

- Baue “richtiges” Python aus den Jupyter Notebooks
- Schreibe Unittests und Integrationstests
- Entwickle eine initiale Deployment Infrastruktur
- Automatisiertes Training und Evaluation
- Es ist okay die Anwendung am User zu entwickeln

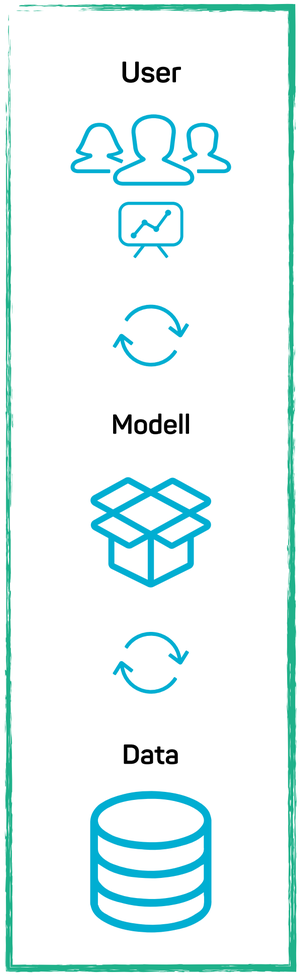

Professionalisierung des Systems

Ziel: Continuous Improvement Cycle und Monitoring

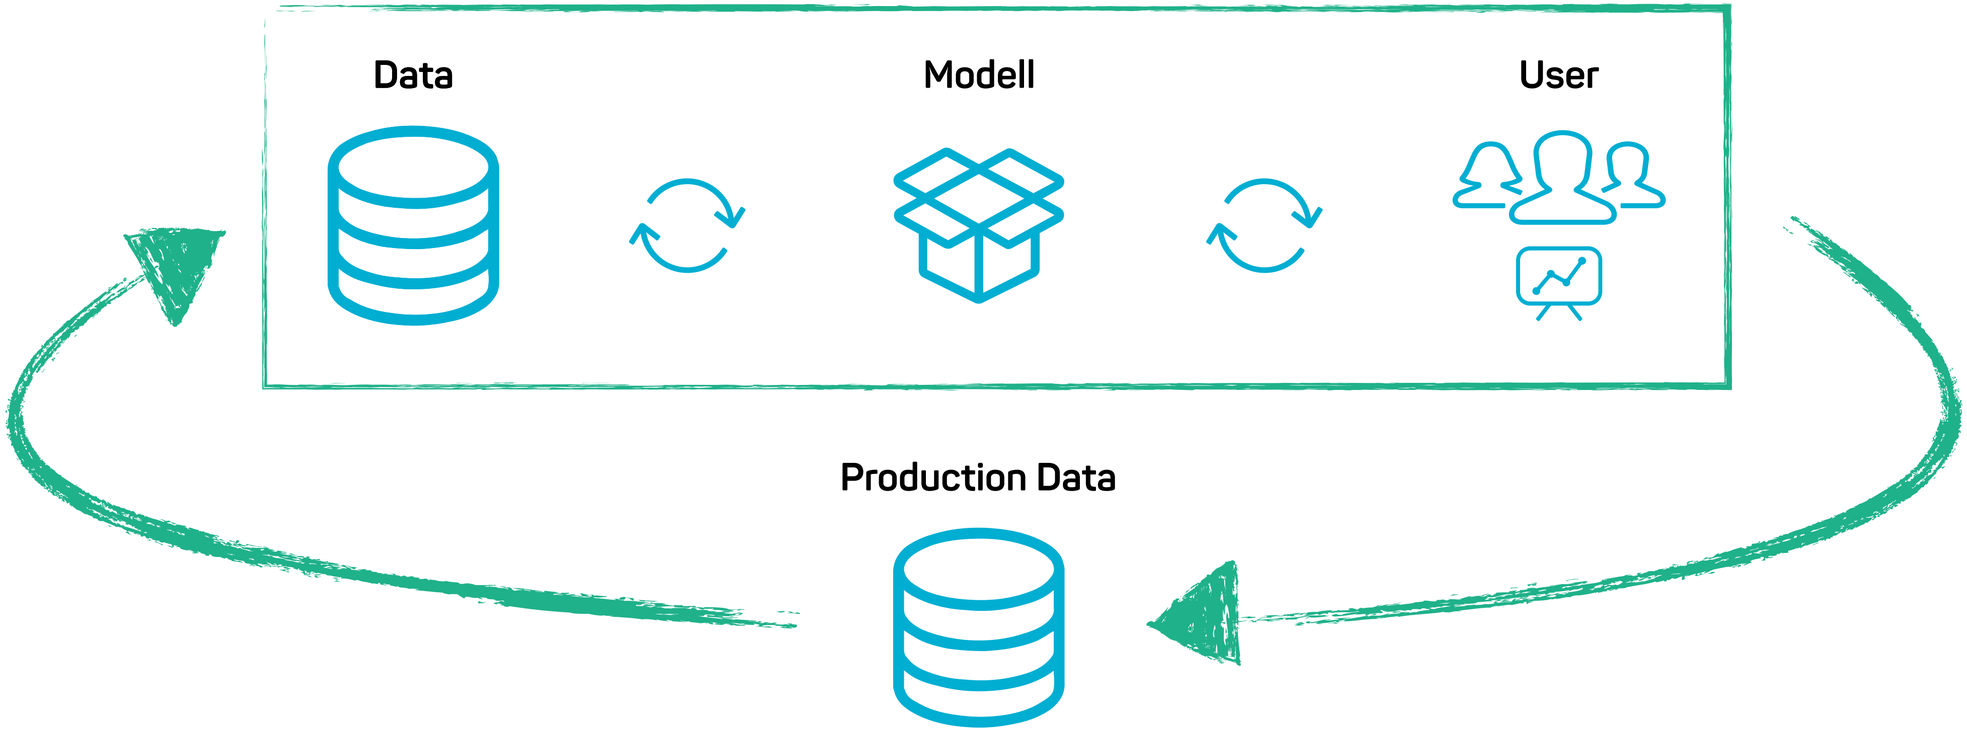

Take aways

- ML in Production ist schwer
  - Engineering & Science Perspektive
  - Komplexe ML-Systeme
  - Mehr Software & Engineering als vermutet

- „Klassische“ Lösungen aus der SE
- Vermehrt spezialisierte Lösungen bis hin zu Komplettansätzen
- Cloud kann die Fertigungstiefe verringern

- Vorgehen:
  - PoC schrittweise ausbauen
  - Nicht mit Plattform starten

Versioning and Reproducable Training

- Data Science is experiment-driven ...

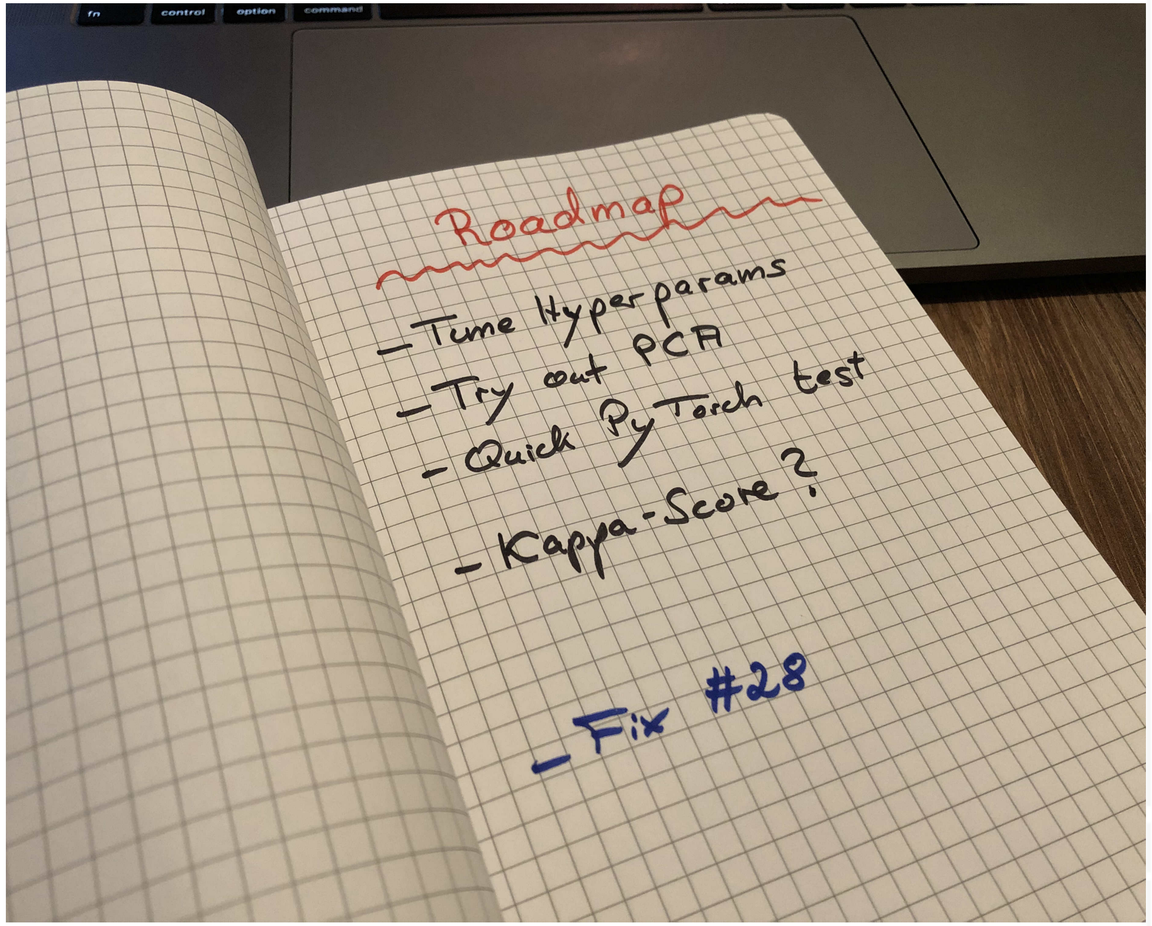

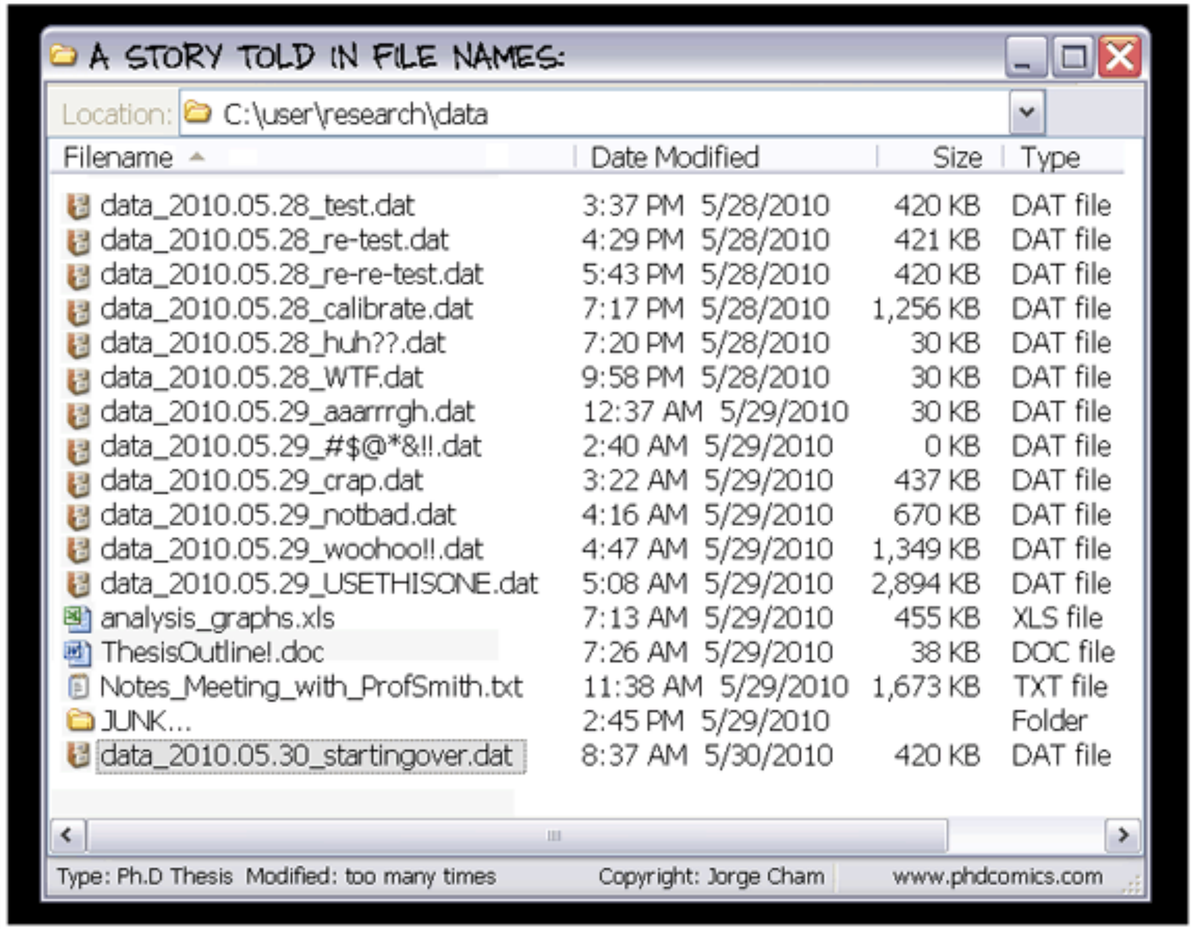

Reproducable Training

- ... and collaborative!

```
Tims-MacBook-Pro:code tsabsch$ git log --graph --decorate --oneline
*   fc88d36 (HEAD -> master) Merge branch 'tim_fix_zerodivisionerror'
|\
| * 2cc23f0 (tim_fix_zerodivisionerror) Fix ZeroDivisionError
* |   e486d76 Merge branch 'mark_batchnorm'
|\ \
| |/
|/|
| * b988f6e (mark_batchnorm) Decrease BN threshold
| * c83736d Add batch normalisation
* | f80b108 Add preprocessing
|/
* a87aa63 Add simple tensorflow model
* 7c0d21e Initial commit
Tims-MacBook-Pro:code tsabsch$
```

Modelmanagement - by hand - hyper parameters

A	B	C
Date	**Alpha**	**L1_ratio**
2019-04-03 1:00 PM	1	1
2019-04-03 4:00 PM	1	0.5
2019-04-04 9:00 AM	1	0.2
2019-04-04 11:00 AM	1	0

Modelmanagement - by hand - metrics

A	B	C	D	E	F
Date	**Alpha**	**L1_ratio**	**mea**	**r2**	**mse**
2019-04-03 1:00 PM	1	1	0.649	0.04	0.862
2019-04-03 4:00 PM	1	0.5	0.648	0.046	0.859
2019-04-04 9:00 AM	1	0.2	0.628	0.125	0.823
2019-04-04 11:00 AM	1	0	0.619	0.176	0.799

Modelmanagement - by hand - model

	A	B	C	D	E	F	G
1	**Date**	**Model**	**Alpha**	**L1_ratio**	**mea**	**r2**	**mse**
2	2019-04-03 1:00 PM	model_v7.p	1	1	0.649	0.04	0.862
3	2019-04-03 4:00 PM	model_v7_l1-05.p	1	0.5	0.648	0.046	0.859
4	2019-04-04 9:00 AM	model_v7_l1-02_d3.p	1	0.2	0.628	0.125	0.823
5	2019-04-04 11:00 AM	model_v7_l1-zero_d3.p	1	0	0.619	0.176	0.799

Modelmanagement - by hand - data

	A	B	C	D	E	F	G	H
1	**Date**	**Dataset**	**Model**	**Alpha**	**L1_ratio**	**mea**	**r2**	**mse**
2	2019-04-03 1:00 PM	data_v2	model_v7.p	1	1	0.649	0.04	0.862
3	2019-04-03 4:00 PM	data_v2	model_v7_l1-05.p	1	0.5	0.648	0.046	0.859
4	2019-04-04 9:00 AM	data_v2_upd_May	model_v7_l1-02_d3.p	1	0.2	0.628	0.125	0.823
5	2019-04-04 11:00 AM	data_v2_upd_May	model_v7_l1-zero_d3.p	1	0	0.619	0.176	0.799

Modelmanagement - by hand - code

A	B	C	D	E	F	G
Date	**Dataset**	**Model**	**Commit**	**Alpha**	**L1_ratio**	**mea**
2019-04-03 1:00 PM	data_v2	model_v7.p	9a5a01b	1	1	0.64
2019-04-03 4:00 PM	data_v2	model_v7_l1-05.p	9a5a01b	1	0.5	0.64
2019-04-04 9:00 AM	data_v2_upd_May	model_v7_l1-02_d3.p	9a5a01b	1	0.2	0.62
2019-04-04 11:00 AM	data_v2_upd_May	model_v7_l1-zero_d3.p	c8b2c10	1	0	0.61

DVC to the Rescue!

- **Large File Storage**, similar to git-lfs
- Metadata in git (name, hashsum etc.)
- Contents in cache + remote storage

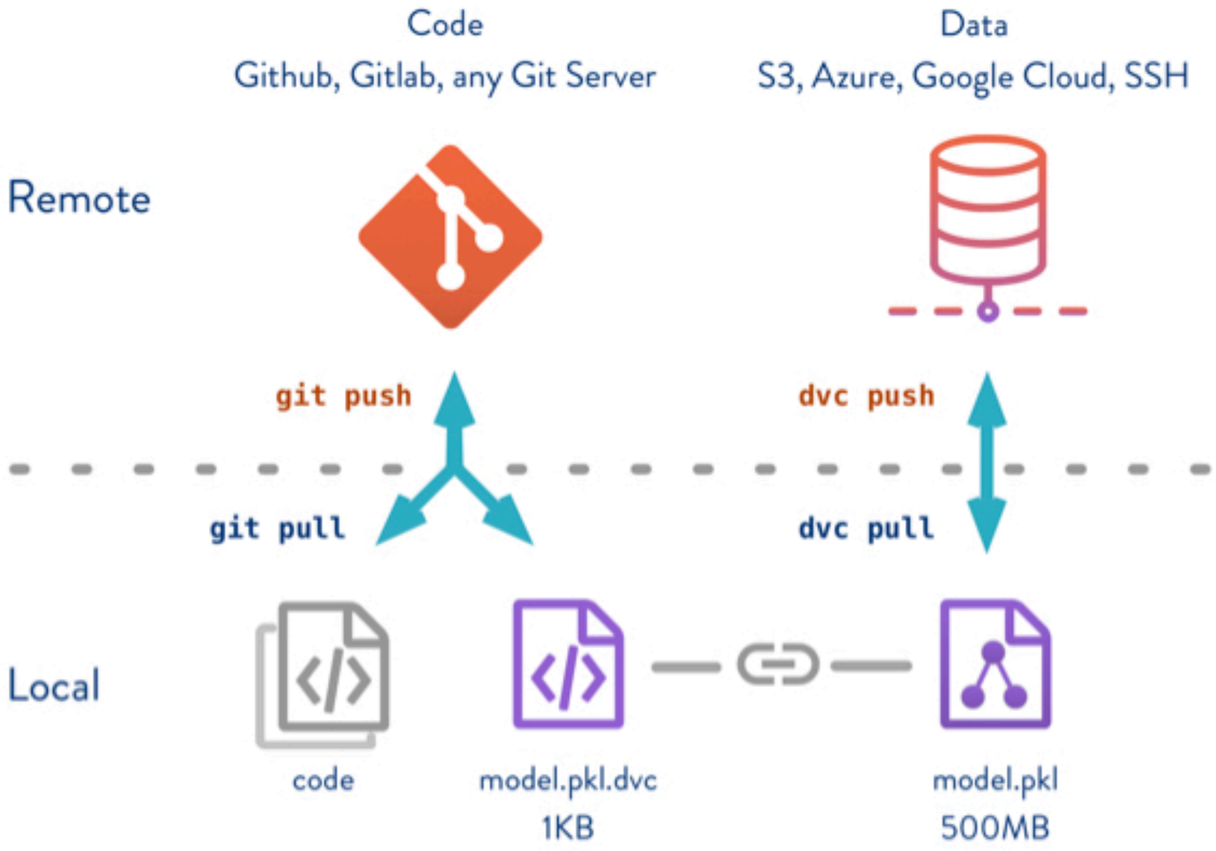

https://dvc.org

DVC to the Rescue!

- **Pipelines**
- Optimize reproduction by splitting your process into stages
- Stages store dependencies, processing and output artefacts

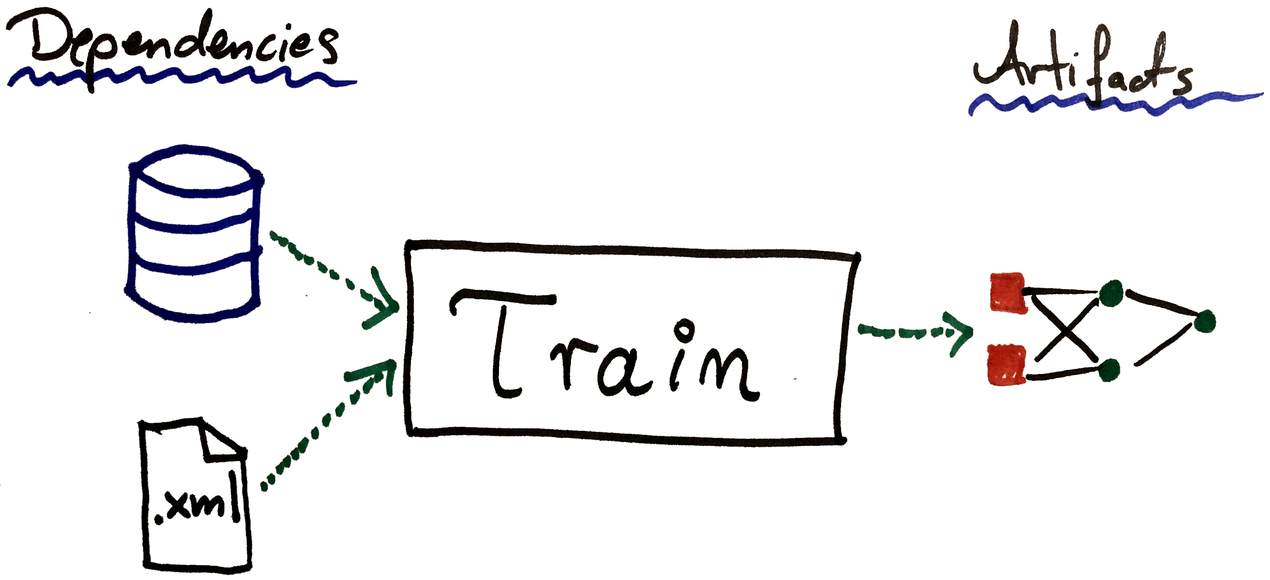

DVC to the Rescue!

- **Pipelines**
- Connect stages to a pipelines via dependencies

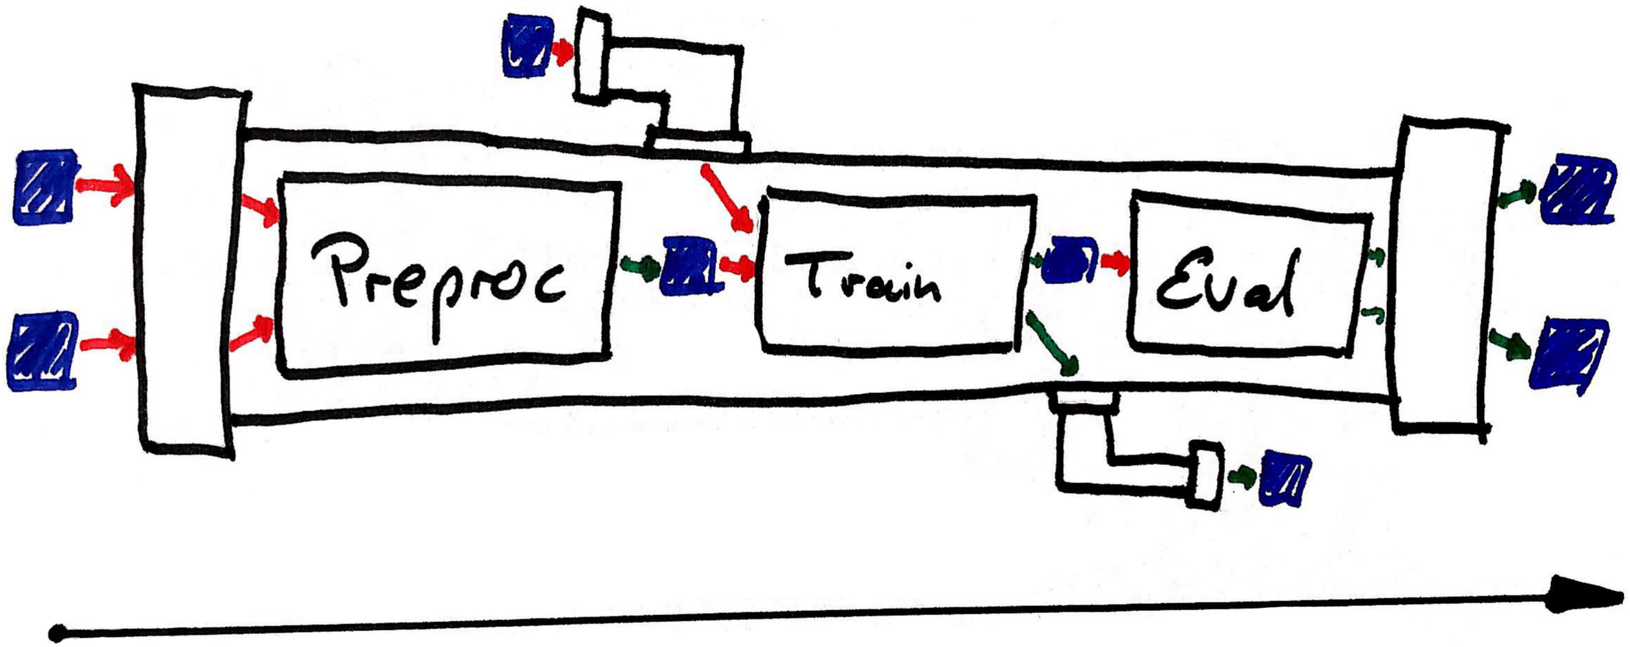

Let's get Practical: DVC

Deployment - Scheduling & Orchestrierung

- Scheduling -> Airflow/Luigi
  - Tool for continuous execution of the cycle
  - Solves dependencies between tasks

- Orchestration with
  - Feature engineering
  - Hyperparameter tuning

Model Serving with Tensorflow Serving

- Lightweight model server for Tensorflow graphs
- Useful for
  - Distributed model applications
  - Fast and continuous delivery
  - Model versioning

Tensorflow Serving

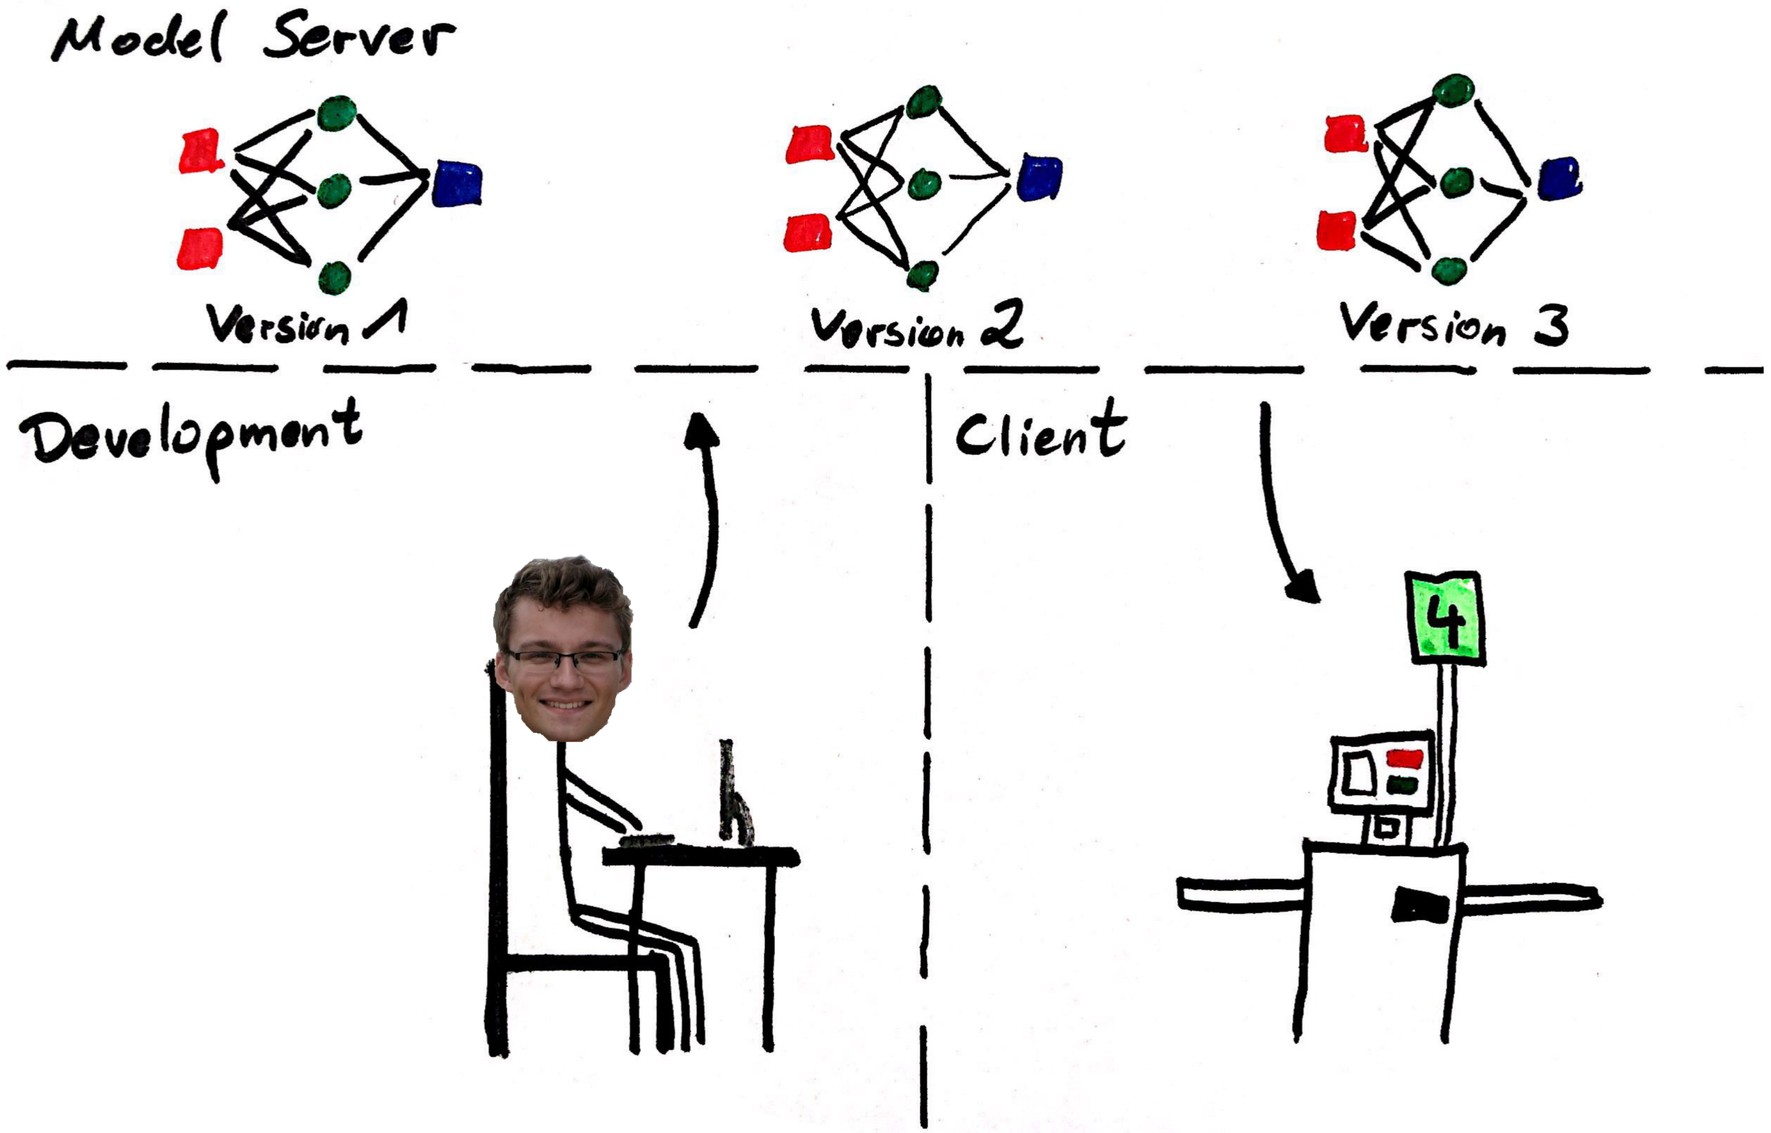

TensorFlow Serving in Detail

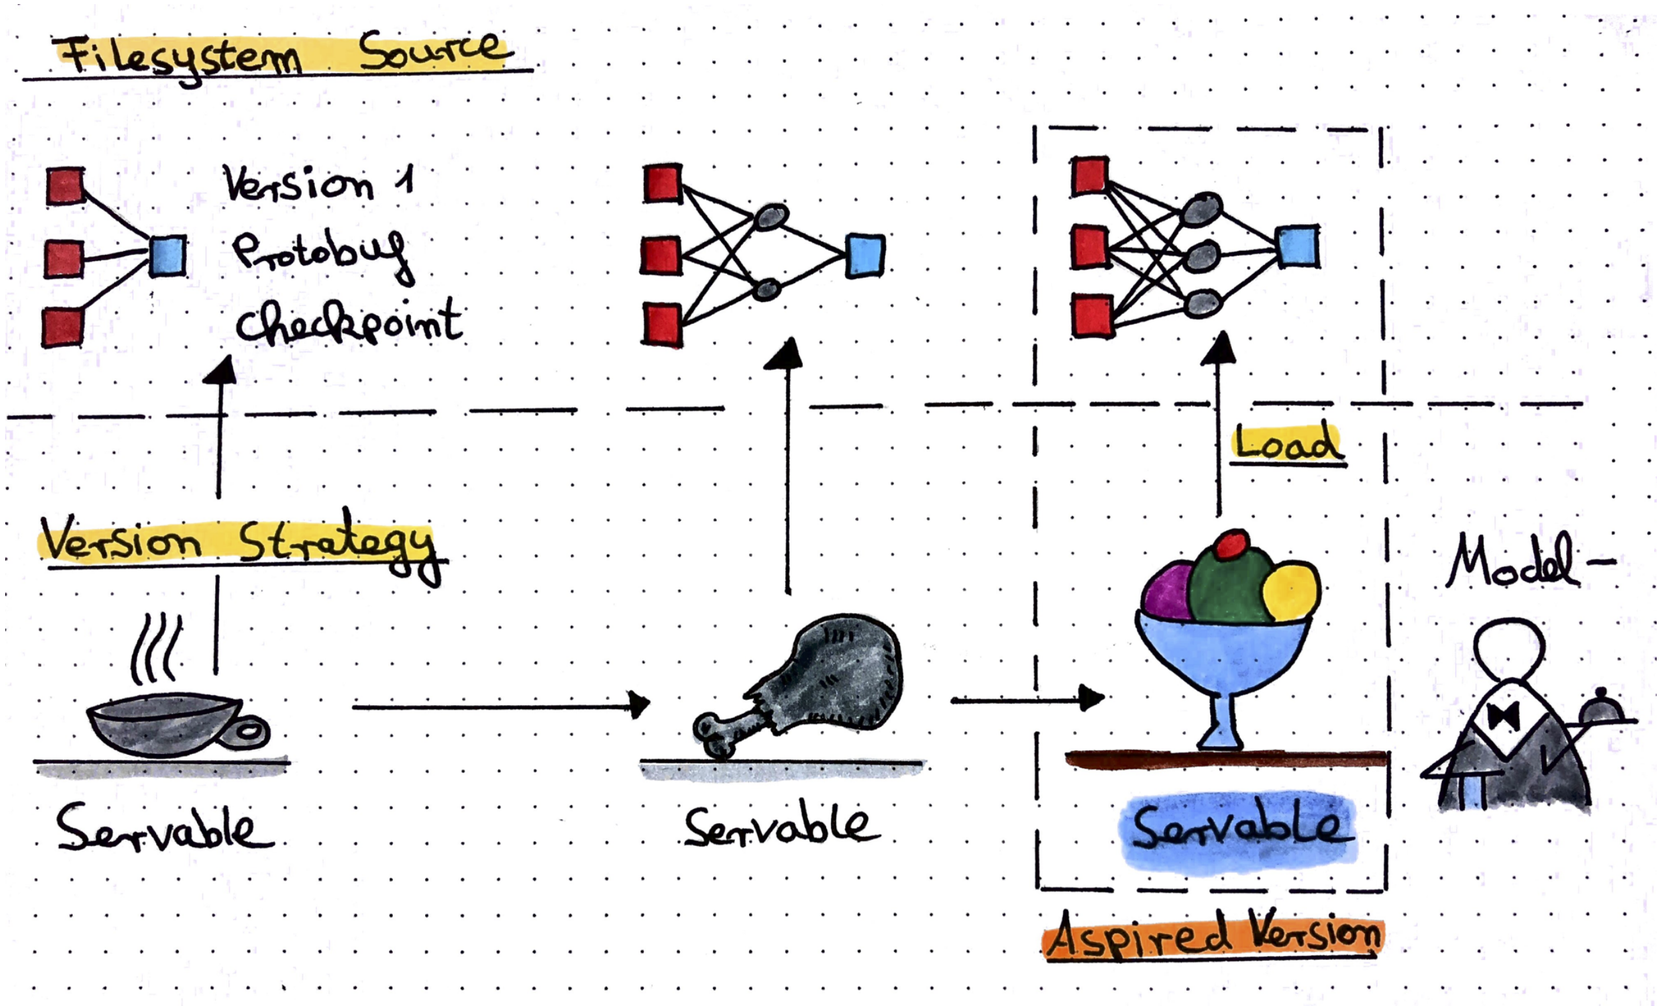

Let's get Practical: Tensorflow Serving

Preprocessing and the Deployment

- Preprocessing and model are tightly coupled
- How can the client "be sure" to do the right thing?

Possible solutions

- The client just knows
- Wrapper service around model and expose API
- Integrate preprocessing into the model

Preprocessing and the Deployment

```
import tensorflow as tf
from keras.layers import Lambda

def preprocess(x):
  resized = tf.image.resize_images(x, size=[100, 100])
  max_color = tf.constant(255, dtype=tf.float32)
  rescaled = tf.divide(resized, max_color)
  return rescaled

additional = Lambda(preprocess, output_shape=(100, 100, 3), name="preprocessing")
```

Preprocessing and the Deployment

```
from keras.models import Sequential
from keras.layers import InputLayer

prod_model = Sequential()
prod_model.add(InputLayer(input_shape=(None, None, 3)))
prod_model.add(additional)

for layer in model.layers:
    prod_model.add(layer)
```